

人工智能导论_开卷考试速查

《人工智能导论》开卷考试知识点速查

依据课堂 PPT 与例题整理。命题倾向：考“核心定义/公式含义/算法步骤/参数作用/易混概念/退化情形”。优先记： A^* 的 $f = g + h$ 、Alpha-Beta 剪枝条件、MCTS 四阶段、GA 三算子、PSO 位置速度更新、学习类型、线性/逻辑回归损失、KMeans 局限、SVM 最大间隔、ID3/C4.5/CART 区别、强化学习 γ 。

0. 一页总览

模块	必背关键词	常见问法/答案
A^*	$f(n) = g(n) + h(n)$; g 已走代价; h 启发估计	$h = 0 \Rightarrow$ 统一代价搜索/Dijkstra; 只看 $h \Rightarrow$ 贪婪最佳优先; h 可采纳/一致时 A^* 保最优
极小极大	零和、完全信息、MAX/MIN、效用回传	MAX 选最大, MIN 选最小; 深度受限用评价函数
Alpha-Beta	α =MAX 当前最好下界; β =MIN 当前最好上界; $\alpha \geq \beta$ 剪枝	剪枝不改变 minimax 结果; 排序越好剪得越多
MCTS	选择-扩展-模拟-反传; UCT	不必须人工启发函数; 适合分支大、难写评估函数的博弈
GA	编码、种群、适应度、选择、交叉、变异	变异维持多样性、防局部最优; 交叉组合基因; 选择保留优良
PSO	粒子=解; 速度; $pbest$; $gbest$	更新主要参考个体历史最优 $pbest$ 与群体全局最优 $gbest$
ML 概述	监督/无监督/半监督/强化; 训练/验证/测试	回归输出连续值; 分类输出离散标签; 聚类无标签; 强化学习是序列决策
线性回归	$h_w(x) = w^T x + b$; MSE; 最小二乘/梯度下降	学习率过大可能震荡/发散, 过小收敛慢
逻辑回归	Sigmoid; 二分类概率; 交叉熵	虽名“回归”, 实为分类; Sigmoid 将线性输出映射到 $(0, 1)$
KMeans	指定 K ; 距离; 更新簇中心; SSE	对初值/尺度/异常值敏感; 偏好球状簇, 不能自动发现任意形状簇
SVM	超平面; 支持向量; 最大间隔; 核函数; 软间隔	超平面选择标准是最大化两类最近点到超平面的间隔

模块	必背关键词	常见问法/答案
决策树	熵、信息增益、信息增益率、Gini、剪枝	ID3=信息增益；C4.5=信息增益率；CART 分类=Gini，回归=MSE
强化学习	Agent/Env/State/Action/Reward/Policy； γ	$\gamma = 0$ 只看即时奖励； $\gamma \rightarrow 1$ 更重视长期回报

1. 启发式搜索与博弈搜索

1.1 A* 算法

项	内容
评价函数	$f(n) = g(n) + h(n)$ ，选 OPEN 表中 f 最小节点扩展
$g(n)$	从起点到节点 n 的实际累计代价
$h(n)$	从 n 到目标的估计代价，启发函数
OPEN/CLOSED	OPEN 存待扩展节点；CLOSED 存已扩展节点
退化情形	$h(n) = 0 \Rightarrow f = g$ ，退化为统一代价搜索/Dijkstra；若每步代价相同，可表现为 BFS；只按 h 选点是贪婪最佳优先搜索
最优性条件	h 可采纳： $0 \leq h(n) \leq h^*(n)$ ，不高估真实剩余代价； h 一致： $h(n) \leq c(n, n') + h(n')$ ，则首次取出目标即最优
启发函数强弱	在可采纳前提下， h 越接近真实代价，扩展节点越少；若高估，可能更快但不保证最优
复杂度	最坏时间/空间指数级；主要瓶颈是 OPEN 表

紧凑流程：

```

OPEN={start}; g(start)=0
while OPEN非空: 取f最小n; 若n为目标返回路径; 把n移入CLOSED; 对每个后继m更新g、parent、f并加入/调整OPEN

```

在纸上建立两个列表：

- Open List (待探索)**：记录已发现但未访问的节点，按 f 值升序排列。
- Closed List (已处理)**：记录已经确定最短路径的节点。

估价函数公式： $f(n) = g(n) + h(n)$

- $g(n)$: 从起点到当前节点的**实际代价**
- $h(n)$: 当前节点到终点的**预期代价**（启发值，如曼哈顿距离或欧几里得距离）

1. 初始化

- 将**起点**放入 Open List。

- 计算起点的 f 值（此时 $g = 0$ ）。

2. 循环搜索（重复以下过程）

- **选点**：从 Open List 中挑出 f 值最小的节点，作为“当前节点”。
- **移出**：将该节点从 Open List 移入 **Closed List**。
- **判断**：若该节点是终点，则搜索成功，开始回溯路径；若 Open List 已空但未找到终点，则无解。

3. 扩展邻居

对“当前节点”的所有相邻节点进行检查：

- **若在 Closed List 中**：直接忽略。
- **若不在 Open List 中**：
 1. 计算其 g, h, f 值。
 2. 设置其“父节点”为当前节点。
 3. 放入 Open List 并按 f 排序。
- **若已在 Open List 中**：
 - 检查经由当前节点到达那里的 g 值是否更小。
 - 如果是，更新其 g 和 f 值，并将父节点指向当前节点。

4. 回溯路径

- 从终点开始，根据“父节点”指针逐级往回找，直到起点。

1.2 极小极大搜索 Minimax

项	内容
适用条件	双人、零和、轮流行动、完全信息、确定性博弈，如井字棋、棋类
基本思想	MAX 希望效用最大，MIN 希望效用最小；从叶节点效用向上回传
回传公式	若 s 是 MAX 节点， $V(s) = \max_a V(Result(s, a))$ ；若是 MIN 节点， $V(s) = \min_a V(Result(s, a))$
截断搜索	树太深时设深度限制，用评价函数 $Eval(s)$ 估计非终局局面
易错点	Minimax 假设对手理性且最优；不是贪婪选眼前最大，而是考虑对手反制后的结果

1.3 Alpha-Beta 剪枝

符号	含义
α	MAX 沿当前路径已经保证能得到的最好值/下界；初始 $-\infty$
β	MIN 沿当前路径已经保证能得到的最好值/上界；初始 $+\infty$
剪枝条件	当 $\alpha \geq \beta$ ，当前分支不可能影响最终选择，停止搜索该分支

符号	含义
正确性	与完整 minimax 得到同一决策，只减少无用节点
节点排序	好排序：复杂度可接近 $O(b^{d/2})$ ；坏排序：最坏仍为 $O(b^d)$

紧凑伪代码：

```

AlphaBeta(s, α, β, max?):
  if 终局/截断: return Eval(s)
  if max: v=-∞; for child: v=max(v,AB(child,α,β,false)); α=max(α,v); if α>=β:
    break; return v
  else: v=+∞; for child: v=min(v,AB(child,α,β,true)); β=min(β,v); if α>=β:
    break; return v
  
```

1.4 蒙特卡洛树搜索 MCTS


阶段	做什么	关键词
Selection 选择	从根节点按策略向下选择到可扩展节点	UCT/UCB，平衡探索与利用
Expansion 扩展	添加一个或多个未访问子节点	新动作
Simulation/Rollout 模拟	从新节点随机或半随机走到终局，得到胜负/回报	不必须人工评估函数
Backpropagation 反向传播	将结果沿路径回传，更新访问次数和平均收益	N, W, Q

UCT 常用形式： $UCT_i = \frac{W_i}{N_i} + c\sqrt{\frac{\ln N_p}{N_i}}$ 。第一项利用已有胜率，第二项鼓励探索访问少的节点； c 越大越探索。MCTS 适合围棋等分支巨大、评价函数难设计的问题；模拟次数越多通常越稳定，但不保证有限次必找全局最优。

2. 智能计算：遗传算法 GA 与粒子群 PSO

2.1 遗传算法 GA

• 遗传算法的基本流程



概念	对应优化问题	记忆
个体/染色体	一个候选解	编码后的解
基因	解的一个组成位/变量	染色体片段
种群	一组候选解	并行搜索多个区域
适应度函数	评价解优劣	决定选择概率
选择	优胜劣汰	保留/复制高适应度个体
交叉	重组父代基因	组合已有优良片段
变异	随机改变基因	增加多样性，防止局部最优
精英保留	直接保留最优个体	防止最优解丢失

基本流程：编码 → 初始化种群 → 计算适应度 → 选择 → 交叉 → 变异 → 新种群 → 满足终止条件则输出最优个体，否则循环

设计点	常考内容
编码	位串编码（问题空间参数编码为一维）、二进制编码（映射到二进制位串空间）、实数编码、有序串编码（TSP问题）；编码决定交叉/变异方式
初始种群	通常随机生成；种群太小易早熟，太大计算慢
适应度	最大化可直接用目标；最小化常转为 $fitness = 1/(1 + f)$ 或做平移；设计不当出现欺骗问题；
选择算子	轮盘赌、锦标赛（随机选k取最高）、排序选择；选择压力过大会早熟；精英保留

设计点	常考内容
交叉算子	单点、多点、均匀、算术交叉；交叉概率 p_c 通常较大
变异算子	位翻转、高斯扰动、交换变异；变异概率 p_m 通常较小
终止条件	达最大迭代代数、适应度达到阈值、若干代无改进
缺点	早熟/停滞、参数敏感、收敛速度可能慢、不能保证有限代全局最优
改进	双种群、双倍体、自适应 p_c/p_m 、精英策略、混合局部搜索

易错：选择不是“随机保留全部好个体”，而是按适应度倾向复制；交叉不是增加随机性为主，主要是重组；变异不是计算适应度，主要维持多样性。

对比要素	适应度比例方法	排序方法
选择概率	根据适应度计算出来的	事先设计好的，取决于排序
适应度缺陷	容易出现过早收敛和停滞现象	克服了过早收敛和停滞现象
适应度计算	需要进行适应度值的尺度变换或者定标	不需要进行适应度值的尺度变换或者定标
健壮性		具有更好的健壮性（鲁棒性）

- ◆ 控制参数：种群规模 N ，交叉概率 p_c ，变异概率 p_m 等。
- ◆ 参数选择应该视解决的具体问题而定，到目前为止，还没有一个适用于遗传算法所有应用领域的关于算法参数的理论。

- ◆ 常用的参数范围： $N=20\sim 200$ ；
 $p_c=0.85\sim 1.0$ ；
 $p_m=0.001\sim 0.15$

p_c 越大，产生新个体的速度就越快；
 p_c 过大，组块被破坏的概率也越大；
 p_c 过小，使搜索变慢、停滞。

p_m 过小，不易产生新个体；
 p_m 过大，变成纯粹的随机搜索算法。

选择的作用：优胜劣汰、适者生存；

交叉的作用：保证种群稳定性，朝着最优解的方向进化；

变异的作用：保证种群多样性，避免交叉可能产生的局部收敛。

2.2 粒子群优化 PSO

粒子 i 的第 j 维的**速度和位置更新公式**：

$$v_{ij}(t+1) = v_{ij}(t) + \overset{\text{惯性项}}{c_1 r_1 (p_{ij}(t) - x_{ij}(t))} + \overset{\text{认知项}}{c_2 r_2 (p_{gj}(t) - x_{ij}(t))} \overset{\text{社会项}}{+ c_2 r_2 (p_{gj}(t) - x_{ij}(t))}$$

$$x_{ij}(t+1) = x_{ij}(t) + v_{ij}(t+1)$$

粒子经历过的最优位置 **pbest** : $p_i(t)$

群体经历过的最优位置 **gbest** : $p_g(t)$

粒子速度更新公式包括三项：

◆ **惯性项**：指引粒子继续飞行的先前粒子速度。

◆ **认知项**：粒子重新返回自身所经过的最好位置的趋势，即粒子**自身经验**的影响

◆ **社会项**：粒子被群体当前最好位置吸引的趋势，即**群体经验**的影响

在三部分的共同作用下，粒子根据**自身历史经验**并利用**群体全局信息**，不断调整自己的位置，以期找到**最优解**。

粒子 i 的第 j 维的**速度和位置更新公式**：

$$v_{ij}(t+1) = v_{ij}(t) + \overset{\text{惯性项}}{c_1 r_1 (p_{ij}(t) - x_{ij}(t))} + \overset{\text{认知项}}{c_2 r_2 (p_{gj}(t) - x_{ij}(t))} \overset{\text{社会项}}{+ c_2 r_2 (p_{gj}(t) - x_{ij}(t))}$$

$$x_{ij}(t+1) = x_{ij}(t) + v_{ij}(t+1)$$

粒子经历过的最优位置 **pbest** : $p_i(t)$


群体经历过的最优位置 **gbest** : $p_g(t)$

其中 r_1 和 r_2 为[0,1]间的随机数，以增加搜索随机性； c_1 和 c_2 为**学习因子（加速系数）**，调节学习最大步长，用来控制 $p_i(t)$ 和 $p_g(t)$ 对粒子飞行方向的影响。

若粒子 i 的位置的第 j 维超过范围 $[X_{\min}, X_{\max}]$ ，则取边界值。

若粒子 i 的速度的第 j 维超过范围 $[V_{\min}, V_{\max}]$ ，则取边界值。

位置限制：自变量的取值范围，对于无约束问题此处可以省略



$$\min f(x_1, x_2) = x_1^2 + x_2^2$$

$$-10 \leq x_j \leq 10 \quad j = 1, 2$$

每个粒子有一个位置和一个速度：

$$x_i(t) = \{x_{i1}, x_{i2}, \dots, x_{in}\}$$

$$v_i(t) = \{v_{i1}, v_{i2}, \dots, v_{in}\}$$

粒子经历过的最优位置 **pbest** : $p_i(t)$

群体经历过的最优位置 **gbest** : $p_g(t)$

$$v_{ij}(t+1) = v_{ij}(t) + \boxed{c_1 r_1 (p_{ij}(t) - x_{ij}(t))} + \boxed{c_2 r_2 (p_{gj}(t) - x_{ij}(t))}$$

$$x_{ij}(t+1) = x_{ij}(t) + v_{ij}(t+1)$$

概念	含义
粒子位置 x_i	一个候选解， n 维问题中 $x_i = (x_{i1}, \dots, x_{in})$
粒子速度 v_i	解的移动方向和步长
适应度	用目标函数评价当前位置好坏
$pbest/p_i$	粒子自身历史最优位置
$gbest/p_g$	全群体历史最优位置
惯性项	沿原速度继续飞，保持探索
认知项	向自身最好经验靠近
社会项	向群体最好经验靠近

标准更新： $v_{ij}(t+1) = wv_{ij}(t) + c_1 r_1 (p_{ij}(t) - x_{ij}(t)) + c_2 r_2 (p_{gj}(t) - x_{ij}(t))$ ，
 $x_{ij}(t+1) = x_{ij}(t) + v_{ij}(t+1)$ 。无惯性权重时相当于 $w = 1$ 。 $r_1, r_2 \sim U(0, 1)$ 增加随机性；
 c_1, c_2 是学习因子/加速系数； w 平衡全局探索与局部开发；常需限制 $x \in [X_{min}, X_{max}]$ 、
 $v \in [V_{min}, V_{max}]$ 。

流程：初始化粒子位置/速度 → 计算适应度 → 更新每个粒子的pbest和全局gbest → 按公式更新速度/位置 → 边界处理 → 满足终止条件输出gbest

对比	GA	PSO
灵感	生物进化	鸟群/鱼群协同觅食
个体变化	选择、交叉、变异产生新个体	粒子连续移动
信息传播	优秀个体通过后代传播基因	最优粒子吸引其他粒子
参数	种群规模、 p_c 、 p_m	w, c_1, c_2, V_{max}

对比	GA	PSO
优点	全局随机搜索、适合组合优化	公式简单、参数少、连续优化常收敛快
缺点	可能早熟、速度慢	可能早熟、易陷局部最优、依赖参数/拓扑

3. 机器学习概述

3.1 学习类型与任务

类型	数据	目标	例子	常见算法
监督学习	有标签 (x, y)	学 $y = f(x)$	房价预测、垃圾邮件分类	线性回归、逻辑回归、SVM、决策树
无监督学习	无标签 x	发现结构	用户分群、降维	KMeans、PCA、DBSCAN
半监督学习	少量标签+大量无标签	降低标注成本	自训练、伪标签	半监督分类
强化学习	与环境交互得到奖励	学策略最大化长期回报	机器人走迷宫、游戏 AI	Q-learning、策略梯度

- **监督学习**算法：线性模型linear_model、支持向量机svm、树形模型tree等
- **聚类**算法cluster：K-Means 聚类、DBSCAN 聚类等
- **集成学习**算法 (ensemble)：随机森林、梯度提升、AdaBoost 等
- **数据预处理** (preprocessing)：数据标准化、归一化、编码分类变量等
- **模型选择与评估** (model_selection)：数据集划分、交叉验证、超参数调优等


模型/方法	学习类型	任务类型
线性回归	监督学习	回归
逻辑回归	监督学习	分类
决策树	监督学习	分类、回归
随机森林	监督学习	分类、回归 (集成学习)
SVM	监督学习	分类、回归 (SVR)
KNN	监督学习	分类、回归
贝叶斯算法 (如朴素贝叶斯)	监督学习	分类
神经网络	监督/无监督/强化学习	分类、回归、降维、生成数据、强化学习
集成学习 (如随机森林、梯度提升)	监督学习	分类、回归
强化学习算法 (Q-learning、策略梯度)	强化学习	动态决策任务
K-均值算法	无监督学习	聚类

任务	输出	评价指标
回归	连续值	MSE、RMSE、MAE、 R^2
分类	离散类别/概率	Accuracy、Precision、Recall、F1、AUC
聚类	簇编号	SSE/惯性、轮廓系数、ARI/NMI（有真标签时）
降维	低维表示	保留方差、重构误差

3.2 建模流程与训练技巧

2

机器学习的应用流程



步骤	要点
问题定义	判断是回归、分类、聚类还是序列决策；确定指标
数据准备	收集、清洗缺失/异常/噪声；特征工程；标准化/归一化；划分训练/验证/测试
模型选择	先用简单模型做基线，再考虑复杂模型
训练调优	选择损失函数与优化算法；调学习率、正则化、模型复杂度
测试评估	只在最后用测试集估计泛化能力，避免数据泄漏

概念	公式/解释
损失函数 Loss	单个样本误差；回归常用平方损失，分类常用交叉熵
代价函数 Cost	全训练集平均损失，即经验风险
目标函数 Objective	经验风险 + 正则化项/结构风险
欠拟合	训练误差和测试误差都高；模型太简单/特征不足
过拟合	训练误差低、测试误差高；模型太复杂/数据少/噪声大

概念	公式/解释
正则化	L1 促稀疏；L2 抑制大权重，可缓解过拟合
数据标准化	对 KMeans、SVM、梯度下降很重要；树模型相对不敏感

梯度下降： $w^{t+1} = w^t - \alpha \nabla J(w^t)$ 。 α 为学习率：过大可能越过最低点导致震荡/发散；过小收敛慢。BGD 每步用全量样本，稳定但慢；SGD 每步用一个样本，快但波动；Mini-batch 折中且最常用。

特征工程：特征构建、特征选择、特征降维（主成分分析PCA、线性判别分析LDA）、规范化（标准化、区间缩放、归一化，清除数量级差异）

- **损失函数 (Loss Function)**：度量**单个样本**预测的错误程度，损失函数值越小，模型就越好

- **平方损失**：对于单个样本，模型的预测值和真实值（标签）之间误差的平方，常用于回归问题

$$Loss(y_i, f(x_i)) = (y_i - f(x_i))^2$$

- **交叉熵损失**：衡量模型预测的概率分布与真实分布之间的偏差程度，常用于分类问题

$$Loss(y_i, P(y_i|x_i)) = -\log P(y_i|x_i)$$

训练映射函数 f
使得 $f(x_i)$ 预测结果尽量等于 y_i



训练数据集
 $(x_i, y_i), i = 1, \dots, n$

- **代价函数 (Cost Function)**：在整个训练集上，**所有样本**误差的平均，也就是损失函数的平均，即**经验风险**最小化函数。
- **目标函数 (Object Function)**：最终需要优化的函数，等于经验风险 + 结构风险（也就是 Cost Function + 正则化项）。
 - 模型评估：性能指标——分类问题

二分类混淆矩阵

真实结果	预测结果	
	正例	反例
正例	TP	FN
反例	FP	TN

- **查准率**（也称**精确率**）：预测结果为正的样本有多少实际也为正

$$\text{查准率 } P = \frac{TP}{TP + FP}$$

- **查全率**（也称**召回率**）：实际为正的样本中有多少样本的分类结果也为正

$$\text{查全率 } R = \frac{TP}{TP + FN}$$

- **正确率**：分类正确的样本数占样本总数的比例

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$

- **F1分数**：综合考虑查准率与查全率的度量

$$F_1 = \frac{2 \times P \times R}{P + R}$$

真正率TPR/灵敏度(Sensitivity)/召回率(Recall):
 $sensitivity = TPR = \frac{TP}{TP + FN}$ 识别正样本的能力

特异性/真负率TNR (True Negative Rate) :
 $specificity = \frac{TN}{TN + FP}$ 识别负样本的能力

真实需求: 即能找正样本, 也能找出负样本

◆ **过拟合**: 所构建的机器学习模型在训练集上表现的很好, 但在测试集上表现很差, 推广泛化能力差。

◆ 过拟合问题往往是由于训练数据少和噪声等原因造成的。

◆ **解决方法**: 1.数据集扩增; 2.对数据进行K折交叉验证; 3.选取合适的停止训练标准; 4.正则化; 5.降维 (PCA) 等。



FPR (False Positive Rate)

$$FPR = \frac{FP}{FP + TN}$$

假正率FPR/误检率衡量模型误报的程度。FPR越低, 特异性越高, 说明误报越少。

4. 线性回归 Linear Regression

2 线性回归



● **梯度下降法**是解决回归模型中最简单且有效的方法之一, 当特征数量n大时也能较好适用, 适用于各种类型的模型。

1) 首先对初始的 w 赋值, 可以随机, 也可以为一个全零的向量。

2) 改变 w 的值, 使得 $J(w)$ 沿着**负梯度**方向进行减少。

$$h_w(x) = w^T x$$

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (h_w(x^{(i)}) - y^{(i)})^2$$


第i个样本的真实值

第i个样本的预测值

$$w^{t+1} = w^t - \alpha \frac{\partial}{\partial w} J(w)$$

学习率/步长

参数梯度



● 迭代方向: **目标函数 $J(w)$ 值下降最快的方向——负梯度方向**

● 迭代步长: **合适的长度**

项	内容
任务	监督学习中的回归任务, 预测连续值
模型	$h_w(x) = w^T x + b$; 多特征是超平面
目标	找到参数使预测值与真实值误差最小
常用损失	$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (h_w(x^{(i)}) - y^{(i)})^2$
求解	最小二乘/正规方程 $w = (X^T X)^{-1} X^T y$ (需可逆); 梯度下降 (适合高维/大数据)
梯度更新	$w := w - \alpha \frac{1}{m} \sum_i (h_w(x^{(i)}) - y^{(i)}) x^{(i)}$; $b := b - \alpha \frac{1}{m} \sum_i (h_w(x^{(i)}) - y^{(i)})$

项	内容
易错	线性回归对异常值敏感；特征尺度差异大会影响梯度下降速度；学习率不是越大越好

5. 逻辑回归 Logistic Regression

项	内容
任务	监督学习中的分类，常用于二分类，也可扩展多分类
核心	“线性模型 + Sigmoid”： $p = P(y = 1 x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}}$
决策	默认阈值 0.5： $p \geq 0.5$ 判 1，否则判 0；决策边界为 $w^T x + b = 0$
损失	二元交叉熵 $J = -\frac{1}{m} \sum_i [y^{(i)} \log p^{(i)} + (1 - y^{(i)}) \log(1 - p^{(i)})]$
多分类	One-vs-Rest 训练多个二分类器；或 Softmax/多项逻辑回归
正则化	加 L1/L2 防过拟合，L2 常见
易错	名字有“回归”但本质是分类；Sigmoid 作用是把任意实数映射为 (0,1) 概率；输出不是连续预测值而是概率/类别

逻辑回归 vs 线性回归：线性回归用 MSE 预测连续值；逻辑回归用 Sigmoid+交叉熵预测类别概率。逻辑回归的边界仍是线性的，除非手工构造非线性特征。

6. KMeans 聚类

项	内容
类型	无监督学习；聚类；无标签
输入	样本集、预先指定簇数 K
距离	常用欧氏距离，故需注意特征缩放
目标	最小化簇内平方和 $SSE = \sum_{k=1}^K \sum_{x_i \in C_k} \ x_i - \mu_k\ ^2$
步骤	选 K 个初始中心 → 分配每个样本到最近中心 → 用簇内均值更新中心 → 重复直到中心/分配不变或达迭代上限
收敛	SSE 单调不增，有限步收敛到局部最优
优点	简单、快、可解释
局限	对 K 、初始中心、异常值、尺度敏感；偏好球状/凸形/大小相近簇；不能自动发现环形、月牙形等任意形状簇
改进	KMeans++ 改善初始化；多次随机初始化取最优；肘部法/轮廓系数选 K


易错：KMeans 的“中心”是均值，不一定是某个真实样本；KMeans 不是分类，因为没有标签；KMeans 不能自动决定 K 。

7. 支持向量机 SVM


2.3 支持向量机 (SVM)



直观理解： 对一个数据点进行分类，当超平面离数据点的“间隔”越大，分类的确信度 (confidence) 也越大。



支持向量机： 中间直线就是分类超平面，不难发现，用来确定这条直线其实只需要两条虚线上的五个点就够了。



如何从茫茫样本中找出支持向量？

项	内容
任务	主要用于监督分类，也可做回归 SVR
决策函数	$g(x) = w^T x + b$, $f(x) = \text{sign}(g(x))$
超平面	$w^T x + b = 0$; w 决定方向, b 决定偏置
支持向量	离分类超平面最近、决定间隔的样本点
核心思想	在正确分类前提下，最大化两类支持向量到超平面的几何间隔
几何间隔	点到超平面距离与 $\ w\ $ 相关；最大化间隔等价于最小化 $\frac{1}{2} \ w\ ^2$
硬间隔	数据完全线性可分: $\min \frac{1}{2} \ w\ ^2$, s. t. $y_i(w^T x_i + b) \geq 1$
软间隔	允许少量错误/越界: 加入松弛变量 ξ_i 与惩罚参数 C ; C 大更重视训练误差, C 小间隔更宽更平滑
核函数	将低维非线性问题映射到高维线性可分; 常见线性核、多项式核、RBF/高斯核、Sigmoid 核
特点	只由支持向量决定, 解稀疏; 对特征尺度敏感; 小样本、高维场景表现常较好
易错	最大间隔不是“分类错误最少”那么简单; 核函数不是显式升维计算全部坐标, 而是通过内积技巧计算高维相似度

两点 SVM 速算：若只有一个正例 x_+ 和一个负例 x_- ，最大间隔超平面是两点连线的垂直平分线。例：正例 $(-2, 1)$ 、负例 $(1, 2)$ ，中点 $(-\frac{1}{2}, \frac{3}{2})$ ，法向量可取 $(3, 1)$ ，超平面 $3(x + \frac{1}{2}) + (y - \frac{3}{2}) = 0$ ，即 $3x + y = 0$ 。

8. 决策树 Decision Tree

2.5

决策树构建：特征选择




特征选择：决定用哪个特征来划分特征空间，特征选择是要选出对训练数据集具有分类能力的特征，这样可以提高决策树的学习效率。

信息熵 (Entropy)：衡量数据集的混乱程度，表示数据集 D 中类别分布的不确定性，熵越小，数据越纯净（类别越集中）；熵越大，数据越混乱。

信息增益 (Information Gain) = 信息熵(前) - 信息熵(后，也称条件熵)

$|D_i|$: 第 i 类样本数
 $|D|$: 总样本数

假定当前数据集 D 中有 K 类，其中第 i 类样本占比为 p_i ($p_i = \frac{|D_i|}{|D|}$)，则信息熵的计算公式：




$$E(D) = - \sum_{i=1}^K p_i \log_2 p_i$$

$$E(D) = - \frac{30}{60} \log_2 \frac{30}{60} - \frac{30}{60} \log_2 \frac{30}{60} = 1$$

二分类熵最大为1：类别间没有明显差异，正反例各占50%，分类效果最差的状态

熵最小为0：完全分类的状态，所有样本都是同一类别

贷款问题
类1：给，类2：不给



图A 按属性1进行分裂
性别

2.5

决策树：特征选择



一组标签 $y = \{y_i\}_{i=1}^K$

信息熵 $E(D) = - \sum_{i=1}^K p_i \log_2 p_i$

信息增益 $Gain = E(D) - E(D, A)$

$$= E(D) - \sum_{j=1}^n \frac{|D_j|}{|D|} E(D_j)$$

经验熵

- 二分类类别均分的时候熵最大
- 熵越小，混乱程度越低，纯度越高
- 信息增益越大，划分后复杂度减小得越多，分类效果越明显

条件熵 = 权重 * 经验熵，样本数越多的分支结点的影响越大

$$E(D) = - \frac{30}{60} \log_2 \frac{30}{60} - \frac{30}{60} \log_2 \frac{30}{60} = 1$$

$$E(D_1) = E(D_2) = 1$$

$$\text{信息增益: } Gain_A = E(D) - E(D, A) = E(D) - \frac{20}{60} E(D_1) - \frac{40}{60} E(D_2) = 0$$


$$E(D'_1) = - \frac{28}{33} \log_2 \frac{28}{33} - \frac{5}{33} \log_2 \frac{5}{33} \approx 0.185$$

$$E(D'_2) = - \frac{2}{27} \log_2 \frac{2}{27} - \frac{25}{27} \log_2 \frac{25}{27} \approx 0.115$$


$$\text{信息增益: } Gain_B = E(D) - E(D, B) = E(D) - \frac{33}{60} E(D'_1) - \frac{27}{60} E(D'_2) \approx 0.847$$

特征属性应选择
图A还是图B?

贷款问题
类1：给，类2：不给




图A 按属性1进行分裂
性别



图B 按属性2进行分裂
年龄 > 30

训练数据

Predictors				Decision
Outlook	Temperature	Humidity	Windy	Play Golf?
Rainy	Hot	High	FALSE	No
Rainy	Hot	High	TRUE	No
Overcast	Hot	High	FALSE	Yes
Sunny	Mild	High	FALSE	Yes
Sunny	Cool	Normal	FALSE	Yes
Sunny	Cool	Normal	TRUE	No
Overcast	Cool	Normal	TRUE	Yes
Rainy	Mild	High	FALSE	No



学到的决策树

在学习过程中，每次节点分裂（通过选择某个特征）都以最大化信息增益为准则（贪婪思想、局部优化）

$$E(\text{Root}) = -\frac{4}{8}\log_2\frac{4}{8} - \frac{4}{8}\log_2\frac{4}{8} = 1$$

$$E(\text{Rain}) = -\frac{3}{3}\log_2\frac{3}{3} - \frac{0}{3}\log_2\frac{0}{3} = 0$$

$$E(\text{Sunny}) = -\frac{1}{3}\log_2\frac{1}{3} - \frac{2}{3}\log_2\frac{2}{3} = 0.2442$$

$$E(\text{Overcast}) = -\frac{2}{2}\log_2\frac{2}{2} - \frac{0}{2}\log_2\frac{0}{2} = 0$$

$$\begin{aligned} \text{Gain}_{\text{Outlook}} &= E(\text{Root}) - E(\text{Root}, \text{Outlook}) \\ &= E(\text{Root}) - \frac{3}{8}E(\text{Rain}) - \frac{3}{8}E(\text{Sunny}) - \frac{2}{8}E(\text{Overcast}) \approx 0.908 \end{aligned}$$

$$\begin{aligned} \text{Gain}_{\text{Temperature}} &= E(\text{Root}) - E(\text{Root}, \text{Temperature}) \\ &= E(\text{Root}) - \frac{3}{8}E(\text{Hot}) - \frac{2}{8}E(\text{Mild}) - \frac{3}{8}E(\text{Cool}) \approx 0.543 \end{aligned}$$

$$\text{Gain}_{\text{Humidity}} = E(\text{Root}) - \frac{1}{8}E(\text{High}) - \frac{7}{8}E(\text{Normal}) \approx 0.714$$

$$\text{Gain}_{\text{Windy}} = E(\text{Root}) - \frac{5}{8}E(\text{FALSE}) - \frac{3}{8}E(\text{TRUE}) \approx 0.714$$

项	内容
结构	内部节点=特征测试；分支=测试结果；叶节点=类别/预测值
使用	从根节点按特征值走分支，到叶节点输出类别
构建	贪婪递归选择“最能划分数据”的特征
信息熵	$Ent(D) = -\sum_{k=1}^K p_k \log_2 p_k$ ；越小越纯；二分类 50/50 时最大为 1
条件熵	$Ent(D A) = \sum_v \frac{1}{n} \{$
信息增益	$Gain(D, A) = Ent(D) - Ent(D A)$ ；越大越好
信息增益率	$GainRatio = Gain/IV(A)$ ，缓解信息增益偏好取值多的属性
Gini	$Gini(D) = 1 - \sum_k p_k^2$ ；越小越纯
剪枝	预剪枝：提前停止；后剪枝：先长完整树再剪掉贡献小的子树
过拟合原因	分支过细，学习到噪声/孤立点
优点	可解释、能处理非线性、对特征尺度不敏感、可处理混合特征
缺点	易过拟合、对数据扰动敏感、贪婪局部最优

算法	特征选择	树形/任务	备注
ID3	信息增益	多叉，分类	偏好取值多的属性；适合离散特征
C4.5	信息增益率	多叉，分类	ID3 改进，可处理连续值/缺失值
CART	分类用 Gini，回归用 MSE	二叉，分类/回归	sklearn 决策树主要实现 CART
随机森林 RF	多棵 CART 并行 bagging	分类/回归	降方差、抗过拟合更强

算法	特征选择	树形/任务	备注
GBDT/XGBoost/LightGBM	多棵树串行 boosting	分类/回归	逐步拟合残差/梯度

常考计算：遇到 $0 \log 0$ 按 0 处理；算信息增益时，分裂后熵要按分支样本数加权。

9. 强化学习 Reinforcement Learning

概念	含义
Agent	智能体，做决策者
Environment	环境，接收动作并返回新状态与奖励
State s	环境状态
Action a	智能体动作
Reward r	即时奖励
Policy $\pi(a s)$	策略，状态到动作的选择规则
Return G_t	累计折扣回报： $G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$
Discount γ	折扣因子， $0 \leq \gamma \leq 1$ ；越大越重视未来
Value $V^\pi(s)$	按策略 π 从状态 s 出发的期望回报
Action-Value $Q^\pi(s, a)$	在 s 执行动作 a 后再按 π 的期望回报
MDP	马尔科夫决策过程 (S, A, P, R, γ) ，当前状态包含决策所需信息

Bellman 思想：当前价值 = 即时奖励 + 折扣后的未来价值。最优动作价值满足

$Q^*(s, a) = \mathbb{E}[r + \gamma \max_{a'} Q^*(s', a')]$ 。Q-learning 更新：

$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ 。 α 是学习率；方括号是 TD 误差。

ϵ -greedy：以 $1 - \epsilon$ 选当前最优动作，以 ϵ 随机探索，平衡探索/利用。

γ 情形	行为
$\gamma = 0$	只关心当前即时奖励，完全短视
$0 < \gamma < 1$	当前与未来都考虑，越远奖励权重越小
$\gamma \rightarrow 1$	更重视长期回报，适合长期规划，但学习更难

易错：强化学习不是监督学习，因为没有每一步的正确标签；奖励可能延迟；“最大化长期累计回报”不等于每一步都贪心拿最大即时奖励。

10. 高频易混点速判

问法	速答
A* 中 $h = 0$ 是什么?	统一代价搜索/Dijkstra; 若边权全相同可等价 BFS
A* 一定最优吗?	不一定; 需 h 可采纳/一致且代价非负
Alpha-Beta 剪枝是不是改变结果?	不改变 minimax 结果, 只少搜索
Alpha-Beta 何时剪?	$\alpha \geq \beta$
MCTS 是否必须人工评估函数?	不必须, 可用 rollout 估计
GA 变异目的?	增加种群多样性, 帮助跳出局部最优
PSO 两个极值?	个体历史最优 $pbest$ 与群体全局最优 $gbest$
监督/无监督/强化的区别?	有标签映射; 无标签找结构; 与环境交互最大化长期奖励
逻辑回归是回归吗?	不是, 常用于分类
KMeans 可以找任意形状簇吗?	不可以, 偏好球状/凸形簇
SVM 超平面标准?	最大化支持向量到超平面的间隔
ID3/C4.5/CART 用什么?	ID3 信息增益; C4.5 信息增益率; CART 分类 Gini、回归 MSE
决策树为什么剪枝?	防止过拟合, 提高泛化
$\gamma = 0$ 的 RL 智能体?	只看即时奖励

11. 开卷考试检索建议

- 计算题优先找公式: $A^* f = g + h$; 线性回归 MSE/梯度; SVM 点到超平面距离; 决策树熵/信息增益; RL Q-learning。
- 概念题优先看“目的”: GA 变异=多样性, PSO $gbest$ =群体历史最优, SVM=最大间隔, KMeans=最小化簇内平方和。
- 判断题注意绝对词: “必须”“一定”“任意形状”“全局最优”通常可疑。
- 表格快速定位: 学习类型表、ID3/C4.5/CART 对比表、GA/PSO 对比表。