

学习内容

CONTENTS

1

神经元与神经网络

2

BP神经网络

3

卷积神经网络



4

生成对抗网络

5

循环神经网络

6

Transformer



案例引入（假币战争）

假设市面上存在一堆不法之徒（G），专门制作逼真的假币，已经在市面上大量流通。

因此警方成立了专门的鉴币专家（D）

□ 深度学习模型分为判别式模型和生成式模型。

- 判别式模型的核心是学习输入到输出的映射关系，例如将一个高维的感官输入映射为一个类别标签。
- 生成式模型的核心是学习数据的概率分布规律，以生成图片为例，生成模型可把随机向量变成与数据集相似的图片，例如生成对抗网络（GAN）、变分自编码器（VAE）、自回归模型（如 GPT 系列的底层架构），以及基于扩散过程的扩散模型（Diffusion Model）、去噪扩散概率模型（DDPM）等。



2014 年到 2018 年，GAN 模型的图片生成效果

Stable Diffusion 是慕尼黑大学2022年8月份推出的文本生成图像的开源模型。Stable Diffusion 属于扩散模型的一种——隐扩散模型（Latent diffusion）。

prompt 为「这幅插画描绘了一颗由半透明玻璃制成的人心，矗立在惊涛骇浪中的基座上。一缕阳光穿透云层，照亮了心脏，揭示了其中的小宇宙。地平线上镌刻着一行醒目的大字『Find the universe within you』」



OpenAI, DALL·E 2
2022.4 ,

DALL·E3




Midjourney, V1 2022.2,
V5

2023 3 15



2023.6.7	Runway	发布	Gen-2模型
2023.11.21	Stability AI	发布	Stable Video Diffusion模型
2023.11.28	PIKA	发布	Pika模型
2024.2.15	OpenAI	发布	Sora模型




□ Ian Goodfellow等于2014年提出生成对抗网络 (**Generative Adversarial Networks, GAN**)，使用**对抗训练机制**对两个神经网络(**生成器Generator**、**判别器Discriminator**)进行训练。




生成对抗网络的结构

•生成器： 像一个"伪造者"，目标是生成逼真的假数据

•判别器： 像一个"鉴定专家"，目标是区分真实数据和生成数据



Yann LeCun曾称GAN为"过去10年机器学习领域最酷的想法"。



生成对抗网络的结构




开始学画、鉴别赏画



生成对抗网络的结构




5年之后




生成对抗网络的结构




10年之后



Nash Equilibrium




纳什均衡




•生成器: 像一个"伪造者", 目标是生成逼真的假数据


•判别器: 像一个"鉴定专家", 目标是区分真实数据和生成数据



Yann LeCun曾称GAN为"过去10年机器学习领域最酷的想法"。




- 生成模型将给定的简单先验分布 $\pi(\mathbf{z})$ (通常是高斯分布) 映射为一个生成概率分布 $p_g(\mathbf{x}|\mathbf{z})$, 通过优化损失函数调整参数 ϕ 使生成概率分布 $p_g(\mathbf{x}|\mathbf{z})$ 尽可能逼近真实数据分布 $p_{data}(\mathbf{x})$ 。




对图片生成任务来说, 生成网络就是拟合训练集图片的像素概率分布 $p_{data}(\mathbf{x})$, 即输出一张服从 $p_g(\mathbf{x}|\mathbf{z})$ 分布的具有训练集特征的图片

生成的手写数字图片


未训练时，可以看到生成的图像完全是随机噪声，判别器也完全没有作用。



训练了50 epoch 后，图像隐隐约约可以看出是什么数字。




训练了100 epoch 后。



当训练了200 epoch 后。



训练了300 epoch 后，虽然没有太大进步了，不过可以看到生成的数字更加自然，不断的竞争当中都在不断成长进步。



torch.Size([64, 1, 28, 28])

CSDN @诺亚方包



真实的手写数字样本

$$z \sim N(\mu=0, \sigma=1)$$

$z = -0.5423$
Latent
representation



$G_\theta(z)$




CSDN @诺亚方包

生成网络输出一张服从生成概率分布 $p_g(x|z)$ 的具有训练集特征的数字图片

判别网络

$$D(x, \theta)$$



D试图输出1

可微函数D

x采样于
真实数据


D试图输出0

可微函数D

x采样于
生成数据

可微函数G

输入
噪音矢量z




判别网络

$$D(x, \theta)$$

$$x \sim p_g(x | z)$$

生成网络

$$G(z, \phi)$$




图例




判别器D



生成器G





$p_g(x|z)$ 可以用深度神经网络来参数化，从均匀分布或高斯分类 $p_z(\cdot)$ 中采样出隐藏变量 z ，经过**多层转置卷积层网络**参数化的 $p_g(x|z)$ 分布中采样出样本 x_f 。从输入输出层面来看，生成器 G 的功能是将隐向量 z 通过神经网络转换为样本向量 x_f ，下标 f 代表假样本 (Fake samples)。



生成网络G

转置卷积构成的生成网络



`torch.nn.ConvTranspose2d()`




转置卷积理解为：
**padding0+旋转kernel
180°+卷积**的操作。

DCGAN(Alec Radford等, Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, 2015)

<https://arxiv.org/pdf/1511.06434.pdf> (ICLR2016)



高质量生成：能够生成逼真的64x64图像

可解释性：潜在空间具有有意义的语义




DCGAN的特点:

- 1.使用卷积层代替池化层
- 2.去掉卷积层之后的全连接层
- 3.使用Batch Normalization
- 4.生成器各层用ReLU，输出用Tanh；判别器各层用LeakyReLU



DCGAN(Alec Radford等, Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks, 2015)

<https://arxiv.org/pdf/1511.06434.pdf> (ICLR



100 updates



1000 updates



2000
updates




5000
updates



10,000
updates



50,000
updates




□ 判别网络 D : 能够很好地分辨出真样本 x_r 与假样本 x_f .

以图片生成为例, 其目标是 최소화 图片的预测值和真实值($y_r=1$: 真实样本 x_r 的标签, $y_f=0$: 生成样本 x_f 的标签)之间的二分类交叉熵损失函数:

$$\theta^* = \operatorname{argmin}_{\theta} - \sum_{x_r \sim p_r(\cdot)} \log D_{\theta}(x_r) - \sum_{x_f \sim p_g(\cdot)} \log(1 - D_{\theta}(x_f))$$

把 $\min_{\theta} \mathcal{L}$ 问题转换为 $\max_{\theta} -\mathcal{L}$, 并写成期望形式:

$$\theta^* = \operatorname{argmax}_{\theta} \mathbb{E}_{x_r \sim p_r(\cdot)} \log D_{\theta}(x_r) + \mathbb{E}_{x_f \sim p_g(\cdot)} \log(1 - D_{\theta}(x_f))$$



- 生成网络 $G(z)$: 假样本 $x_f = G_\phi(z)$ 在判别网络的输出越接近真实的标签越好。希望判别网络的输出 $D(G_\phi(z))$ 越逼近 1 越好, 最小化 $D(G_\phi(z))$ 与 1 之间的交叉熵损失函数:

$$\min_{\phi} \mathcal{L} = CE(D(G_\phi(z)), 1) = -\log D(G_\phi(z))$$

把 $\min_{\phi} \mathcal{L}$ 问题转换成 $\max_{\phi} -\mathcal{L}$, 并写成期望形式:

$$\phi^* = \operatorname{argmax}_{\phi} \mathbb{E}_{z \sim p_z(\cdot)} \log D(G_\phi(z))$$

再次等价转化为:

$$\phi^* = \operatorname{argmin}_{\phi} \mathcal{L} = \mathbb{E}_{z \sim p_z(\cdot)} \log[1 - D(G_\phi(z))]$$

把判别网络的目标和生成网络的目标合并，写成min - max博弈形式：

$$\begin{aligned}\min_{\phi} \max_{\theta} L(D, G) &= E_{x_r \sim p_r(\cdot)} \log D_{\theta}(x_r) + E_{x_f \sim p_g(\cdot)} \log(1 - D_{\theta}(x_f)) \\ &= E_{x \sim p_r(\cdot)} \log D_{\theta}(x_r) + E_{z \sim p_z(\cdot)} \log(1 - D_{\theta}(G_{\phi}(z)))\end{aligned}$$

生成器试图最大化其欺骗判别器的概率，而判别器则试图最小化被欺骗的概率

p_r : 真实数据的分布

p_z : 噪声的分布（通常是高斯分布或均匀分布）

x : 来自真实数据的样本

z : 来自噪声分布的样本

$G(z)$: 生成器根据噪声 z 生成的样本。

$D(x)$: 判别器对真实样本 x 为真的概率估计

$D(G(z))$: 判别器对生成样本为真的概率估计

GAN训练的特点：

1. **无监督学习**，但采用的是有监督的损失
2. 判别网络**D**和生成网络**G****相互交替迭代优化**

GAN的两个相互交替迭代优化的训练阶段:

● 固定生成网络G, 训练判别网络D;

● 固定判别网络D, 训练生成网络G.

两个网络相互对抗的过程, 就是各自网络参数不断调整的过程, 即学习过程。

GAN的训练比较难, 往往不太稳定。

算法 1: GAN 训练算法

随机初始化参数 θ 和 ϕ

repeat

for k 次 do

随机采样隐向量 $\mathbf{z} \sim p_z(\cdot)$

随机采样真实样本 $\mathbf{x}_r \sim p_r(\cdot)$

根据**梯度上升算法**更新 D 网络:

$$\nabla_{\theta} \mathbb{E}_{\mathbf{x}_r \sim p_r(\cdot)} \log D_{\theta}(\mathbf{x}_r) + \mathbb{E}_{\mathbf{x}_f \sim p_g(\cdot)} \log (1 - D_{\theta}(\mathbf{x}_f))$$

随机采样隐向量 $\mathbf{z} \sim p_z(\cdot)$

根据**梯度下降算法**更新 G 网络:


$$\nabla_{\phi} \mathbb{E}_{\mathbf{z} \sim p_z(\cdot)} \log (1 - D_{\theta}(G_{\phi}(\mathbf{z})))$$

end for

until 训练回合数达到要求

输出: 训练好的生成器 G_{ϕ}


每次迭代时, D更新k次, 而G更新1次, 即保证D足够强才能开始训练G



动漫图片生成的训练过程示意


图像修复







斑马→马




马→斑马




航拍图像生成地图



轮廓图像生成照片





白天图像生成对应夜景



多模态图像翻译


从文字描述生成图片

这朵花有着长长的粉色花瓣
和朝上的橘黄色雄蕊。



AI换脸术

- 换脸：以GAN为代表的AI换脸术
- 南加州大学的Pinscreen团队的实时3D变脸技术。
- 美国国防部AI侦测工具，以AI攻AI，反换脸精度99%。



SWAPFACE: <https://www.bilibili.com/video/BV1kL41187mr/>

- 2018年11月7-9日，在乌镇第五届世界互联网大会上，新华社对外宣布：中国首个“人工智能主持人”正式上岗。



新闻播报机器人

2019.2.19 新华社发布站立式合成主播



邱浩——新小浩



屈萌——新小萌

GAN变种介绍 - DCGAN、InfoGAN、CycleGAN、WGAN、Self-Attention GAN、BigGAN

一、DCGAN (2016)


二、InfoGAN (2016)

三、CycleGAN (2017)

四、WGAN (2017)

五、Self-Attention GAN (2018)

六、BigGAN (2019)



InfoGAN分离的特征示意图



BigGAN 生成图片样片 (512 × 512)

GAN在训练中容易出现一些问题，训练过程具有强烈的不稳定性，实验结果随机，具体表现：

- 训练难以收敛，经常出现震荡；


超参数敏感：网络结构、学习率、初始化状态等超参数对网络训练过程影响较大，微量的超参数调整将可能导致网络的训练结果截然不同。

WGAN 从理论层面分析了GAN训练不稳定的原因：实际G训练目标JS散度在不重叠的分布 p 和 q 上的梯度曲面是恒定为0的，因此提出Wasserstein距离。



(a)

GAN 模型良好训练得到的生成样本



(b)


不带 BN层的GAN生成的样本




不带 BN层的WGAN生成的样本

- 训练收敛，但出现**模式崩溃**。


模式崩塌(Mode Collapse): 模型生成的样本单一，多样性很差，例如导致生成模型只生成其中的几种模式



MNIST数据集 tSNE在平面上的展示



图片生成模型崩塌



第一行：未出现模式崩塌现象的生成网络的训练过程，最后一列为**真实分布**，即2D 高斯混合模型，由**8 个高斯模型**混合而成；
第二行：出现模式崩塌现象的生成网络的训练过程，最后一列为真实分布。

解决模式崩溃的两条思路：**改进优化目标**（unrolled GAN、DRAGAN）、**网络架构**（MAD-GAN、MAD-GAN-Sim）

GAN在训练中容易出现一些问题，训练过程具有强烈的不稳定性，实验结果随机，具体表现：

- 训练难以收敛，经常出现震荡；
- 训练收敛，但出现模式崩溃。
- 训练收敛，但还会生成一些没有意义或者现实中不可能出现的图片

Diffusion Models vs GANs

虽然扩散模型近年来很流行，但GANs仍有其优势：

- 推理速度：GAN一次前向传播生成图像，扩散模型需要多步
- 控制精度：StyleGAN在细粒度控制上表现优异
- 计算效率：训练好的GAN模型部署成本低



1. 深度学习中，判别式模型和生成式模型的区别是什么？生成模型主要有哪些？
2. 生成对抗网络（GAN）的结构特点是什么？理解博弈学习（对抗学习）的基本思想和生成网络的基本原理。
3. 生成对抗网络（GAN）的训练有哪些特点？理解生成对抗网络的min-max博弈优化目标。生成对抗网络的主要应用有哪些？
4. 生成对抗网络的主要缺点是什么？理解模式崩溃的含义及成因。