

学习内容

CONTENTS

1

神经元与神经网络

2

BP神经网络

3

卷积神经网络

4

生成对抗网络

5


循环神经网络



6

Transformer

Vaswani, Ashish, et al. "Attention is all you need." *Advances in Neural Information Processing Systems*. 2017.



GPT-4 (2023. 3.15发布), **GPT-5** (2025. 8 发布)
Gemini (2023. 12.6发布), **Gemini 2.5** (2025.3.26发布) **Deepseek** (2025. 1 发布)

人脑每个时刻接收的外界输入信息非常多，包括来源于视觉、听觉、触觉的各种各样的信息。

但就视觉来说，眼睛每秒钟都会发送千万比特的信息给视觉神经系统。

人脑通过**注意力**来解决**信息超载**问题。



视觉注意力示例

- 当一个人在吵闹的鸡尾酒会上和朋友聊天时，尽管周围噪音干扰很多，他还是可以听到朋友的谈话内容，而忽略其他人的声音。（**聚焦式注意力**）
- 同时，如果未注意到的背景声中有重要的词（比如他的名字），他会马上注意到。（**显著性注意力**）



离那么远也能听见别人叫你？

鸡尾酒会效应

注意力可以作用在外部的刺激（视觉、听觉、味觉等），也可以作用在内部的意识（思考、回忆等）



问题1：有多少张扑克牌？



问题2：所有黑色牌的数字之和为多少？

聚焦式注意力是指有预定目的、依赖任务的，主动有意识地聚焦于某一对象的注意力，一般会随着环境、情景或任务的不同而选择不同的信息。

- ▶ 自下而上的无意识的注意力（显著性的注意力，**Saliency Based Attention**）

汇聚（pooling）


- ▶ 自上而下的有意识的注意力（聚焦式注意力，**Focus Attention**，也称为选择性注意力，**Selective Attention**）

会聚（focus）


- 由于优化算法和计算能力的限制，神经网络在实践中很难达到通用近似的能力。
 - 网络不能太复杂（参数太多）

- 如何提高网络能力


- 局部连接
- 权重共享
- 汇聚操作
- ?



人工神经网络中的注意力机制



Try to find 8 less than 8 seconds



- 软性注意力机制 (soft attention mechanism) : 选择的信息是所有输入向量在**注意力分布**下的期望

- 注意力机制可以分为两步

- 计算注意力分布 α ,

$$\alpha_n = p(z = n | \mathbf{X}, \mathbf{q})$$

$$= \text{softmax}(s(\mathbf{x}_n, \mathbf{q}))$$


$$= \frac{\exp(s(\mathbf{x}_n, \mathbf{q}))}{\sum_{j=1}^N \exp(s(\mathbf{x}_j, \mathbf{q}))}$$

注意力变量 $z \in [1, N]$ 来表示被选择信息的索引位置

$s(\mathbf{x}_n, \mathbf{q})$ 打分函数
计算每个输入向量和查询向量之间的相关性

- 根据 α 来计算输入信息的加权平均。

$$\begin{aligned} \text{att}(\mathbf{X}, \mathbf{q}) &= \sum_{n=1}^N \alpha_n \mathbf{x}_n, \\ &= \mathbb{E}_{z \sim p(z | \mathbf{X}, \mathbf{q})} [\mathbf{x}_z] \end{aligned}$$



从 N 个输入向量 $[\mathbf{x}_1, \dots, \mathbf{x}_N]$ 中选出和某个特定任务相关的信息



$\mathbf{v}$ 是一个向量，用于将 $\tanh$ 函数的结果映射成一个标量得分

加性模型

$$s(\mathbf{x}, \mathbf{q}) = \mathbf{v}^\top \tanh(\mathbf{W}\mathbf{x} + \mathbf{U}\mathbf{q}),$$

点积模型

$$s(\mathbf{x}, \mathbf{q}) = \mathbf{x}^\top \mathbf{q},$$

缩放点积模型

$$s(\mathbf{x}, \mathbf{q}) = \frac{\mathbf{x}^\top \mathbf{q}}{\sqrt{D}},$$


双线性模型

$$s(\mathbf{x}, \mathbf{q}) = \mathbf{x}^\top \mathbf{W} \mathbf{q},$$

其中 $\mathbf{W}, \mathbf{U}, \mathbf{v}$ 为可学习的参数， D 为输入向量的维度

➤ 文本分类

<http://implicitemotions.wassa2018.com/paper/7.pdf>



注意力模型则能够动态地聚焦于文档中更重要的部分

$$u_{ti} = \tanh(W h_{ti} + b),$$

$$\alpha_{ti} = \frac{\exp(u_{ti}^T u_w)}{\sum_{j=1}^n \exp(u_{tj}^T u_w)},$$

$$s_t = \sum_i \alpha_{ti} h_{ti}.$$

t 第 t 条推文

i 该推文中的第 i 个词语


h_{ti} 第 t 条推文中第 i 个词语的标注向量

u_w 随机初始化的词语级上下文向量


α_{ti} 第 t 条推文中第 i 个词语的贡献权重

the architecture of BiLSTM-Attention model in Emotion Classification


Seq2Seq模型



以一个**固定维度中间语义向量****s**作为编码器输出会丢失很多细节信息，因此循环神经网络难以处理输入的长句子，一般的**Seq2Seq**模型存在信息表示的瓶颈

神经机器翻译
NMT


编码器-解码器框架结合**注意力机制**可以使解码器在生成每个词时，根据当前生成词的需求，重新分配对源句子各个部分的关注度。




注意力机制:

➤ 解码阶段，对于目标语言句子中的每一个词 y_t ，解码器不仅仅依赖前一时刻的状态 y_{t-1} ，还会根据当前解码的位置对源句子的所有隐藏状态进行加权求和，形成一个上下文向量。

➤ 权重即为**注意力分布**，反映了源句子中哪些部分对于当前目标词的生成更为重要。



神经机器翻译NMT(2014)注意力权重的可视化



注意力机制：连接编码器的图像特征和解码器的语言生成过程，让模型在生成每个词时“关注”图像的特定区域。

<http://kelvinxu.github.io/projects/capgen.html>

remote(0.23)



a(0.41)



sky(0.61)



on(0.27)



red(0.38)



woman(0.36)



of(0.19)



A(0.99)




racket(0.16)




a(0.33)



sink(0.48)



of(0.20)




(1) Soft Attention (确定性注意力)

- 对图像特征网络的每个区域计算权重（通过多层感知机 MLP 实现），再对所有区域特征进行加权求和，得到当前时间步的上下文向量。权重通过 Softmax 归一化，满足可微性，能直接用反向传播训练。


(2) Hard Attention (随机性注意力)

- 在图像特征网络中随机采样一个区域（服从多元伯努利分布，每次仅一个区域权重为 1，其余为 0），仅用该区域的特征生成上下文向量。由于采样操作不可微，需用强化学习（策略梯度）优化。

- 硬性注意力 (hard attention) : 只关注一个输入向量 (最大采样或随机采样)
- 键值对注意力 (key-value pair attention) : “键”用来计算注意力分布 α_n , “值”用来计算聚合信息



(a) 普通模式



(b) 键值对模式


用 $(K, V) = [(k_1, v_1), \dots, (k_N, v_N)]$ 表示 N 个输入信息

$$\begin{aligned} \text{att}((K, V), q) &= \sum_{n=1}^N \alpha_n v_n, \\ &= \sum_{n=1}^N \frac{\exp(s(k_n, q))}{\sum_j \exp(s(k_j, q))} v_n \end{aligned}$$

A Simple Example: Search



Understanding Attention with Search



GIANT SEA TURTLES - AMAZING CORAL REEF FISH - 12 HOURS of THE BEST RELAX MUSIC

9.1M views · 4 weeks ago

Full Screen

Enjoy 12 hours of giant sea turtles. This video features swimming coral reef fish and relaxing music for deep sleep and ...



MIT 6.S191 (2020): Introduction to Deep Learning

1M views · 1 year ago

Alexander Amiri

MIT Introduction to Deep Learning 6.S191: Lecture 1 Foundations of Deep Learning Lecturer: Amiri January 2020 For ...

CC



The Kobe Bryant Fadeaway Shot

220K views · 1 year ago

Full Screen

Watch the Kobe Bryant Fadeaway Shot in 4K. This video is a tribute to the late Kobe Bryant and his iconic fadeaway shot.

Query (Q)

Key (K_1)


Key (K_2)

Key (K_3)

How similar is the key to the query?

1. **Compute attention mask:** how similar is each key to the desired query?

Understanding Attention with Search



Query (Q)

Key (K_1)

Key (K_2)


Value (V)

Key (K_3)


2. Extract values based on attention:
 Return the values highest attention

自注意力模型

当使用神经网络来处理一个变长的向量序列时，我们通常可以使用**卷积网络**或**循环网络**进行编码来得到一个相同长度的输出向量序列。



(a) 卷积网络




(b) 双向循环网络

只建模了输入信息的局部依赖关系

循环网络理论上可以建立长距离依赖关系，但是由于信息传递的容量以及梯度消失问题，实际上也只能建立短距离依赖关系


如何建立非局部 (Non-local) 的依赖关系

➤ 全连接?



(a) 全连接模型


无法处理变长问题



(b) 自注意力模型

连接权重 α_{ij} 由注意力机制动态生成


自注意力建模序列数据是没有recurrence的，也就是说没有隐状态之间是没有用于记忆的连接



1. 动态计算权重: 对于不同的查询向量，即使是在同一个序列中，所计算出的注意力权重也会不同

2. 并行化处理: 可以并行计算序列中所有元素之间的关系，可以更高效地运行，同时仍然能够有效地捕捉到序列中的长距离依赖关系

3. 自适应关注重要信息: 通过动态计算注意力权重，自注意力模型能够自适应地关注输入序列中更重要的部分。



W_q , W_k , W_v : 三个投影矩阵——点睛之笔”

Q “我要找什么”：每个 Token 的 Q 向量是其“查询意图”的表示，用于主动寻找序列中相关的 Token。

K “我有什么”：每个 Token 的 K 向量是其“特征标识”的表示，用于被其他 Token 的 Q 匹配。

V “我能提供什么”：每个 Token 的 V 向量是其“核心信息”的表示，用于在匹配后传递有用内容。

通过拆分 Q、K、V 的功能，结合可学习的投影映射，既实现了“动态寻找相关 Token”（Q-K 匹配），又保证了“高效提取有用信息”（V 的传递），最终让模型能灵活捕捉序列中的全局依赖和复杂语义。

Self-Attention 虽然能很好解决语句中各单词之间的相关性问题的，但由于 self-attention 在计算时并不考虑两个单词之间的位置关系，导致在 decoder 时无法解决语句中单词顺序的问题。

• 输入序列为 $X = [x_1, \dots, x_N] \in \mathbb{R}^{D_x \times N}$

1. 位置信息编码

$$p_{t,2i} = \sin(t/10000^{2i/D}),$$

$$p_{t,2i+1} = \cos(t/10000^{2i/D}),$$


$$X = [e_{x_1} + p_1, \dots, e_{x_N} + p_N]$$

2. 生成三个向量序列

$$Q = W_q X \in \mathbb{R}^{D_k \times N},$$


$$K = W_k X \in \mathbb{R}^{D_k \times N},$$

$$V = W_v X \in \mathbb{R}^{D_v \times N},$$



自注意力机制本身并不包含对位置信息的显式建模

目标：识别和关注输入信息中最重要的特征



如果缺失了序列顺序信息，可能会导致所有词语都对，但是无法组成有意义的语句

• 输入序列为 $X = [x_1, \dots, x_N] \in \mathbb{R}^{D_x \times N}$

1. 位置信息编码 $p_{t,2i} = \sin(t/10000^{2i/D})$,

$$p_{t,2i+1} = \cos(t/10000^{2i/D}),$$

2. 生成三个向量序列


$$Q = W_q X \in \mathbb{R}^{D_k \times N},$$

$$K = W_k X \in \mathbb{R}^{D_k \times N},$$

$$V = W_v X \in \mathbb{R}^{D_v \times N},$$

3. 计算注意力权重

Attention weighting: where to attend to!
How similar is the key to the query?




$$\text{softmax} \left(\frac{K^T \cdot Q}{\text{scaling}} \right)$$

Attention weighting

• 如果使用缩放点积来作为注意力打分函数，注意力权重（分布）为

$$\text{softmax} \left(\frac{K^T Q}{\sqrt{D_k}} \right)$$



• 输入序列为 $X = [x_1, \dots, x_N] \in \mathbb{R}^{D_x \times N}$

1. 位置信息编码 $p_{t,2i} = \sin(t/10000^{2i/D}),$

$$p_{t,2i+1} = \cos(t/10000^{2i/D}),$$

2. 生成三个向量序列

$$Q = W_q X \in \mathbb{R}^{D_k \times N},$$

$$K = W_k X \in \mathbb{R}^{D_k \times N},$$


$$V = W_v X \in \mathbb{R}^{D_v \times N},$$

3. 计算注意力权重

4. 用高的注意力提取特征 (如果使用缩放点积来作为注意力打分函数, 输出向量序列可以简写为)

$$H = V \operatorname{softmax}\left(\frac{K^T Q}{\sqrt{D_k}}\right),$$

Last step: self-attend to extract features



$$V \cdot \operatorname{softmax}\left(\frac{Q \cdot K^T}{\text{scaling}}\right) = A(Q, K, V)$$

• 输入序列为 $X = [x_1, \dots, x_N] \in R^{D_x \times N}$

1. 位置信息编码 $p_{t,2i} = \sin(t/10000^{2i/D}),$

$$p_{t,2i+1} = \cos(t/10000^{2i/D}),$$

2. 生成三个向量序列

$$Q = W_q X \in R^{D_k \times N},$$


$$K = W_k X \in R^{D_k \times N},$$

$$V = W_v X \in R^{D_v \times N},$$


3. 计算注意力权重

4. 提取高注意力的特征 (如果使用缩放点积来作为注意力打分函数, 输出向量序列可以简写为)

$$H = V \operatorname{softmax}\left(\frac{K^T Q}{\sqrt{D_k}}\right),$$




多头类似图像处理的多通道



多头自注意力可以在多个不同的“视角”（投影空间）中捕捉不同的交互信息

Attending to the most important parts of an input.



1. Identify which parts to attend to
2. Extract the features with high attention

Similar to a
search problem!

Applying Multiple Self-Attention Heads



Attention weighting

×



Value

=




Output



Output of attention head 1





Output of attention head 2





Output of attention head 3

- 仅仅自注意力还不够
- 其它操作
 - 位置编码
 - 层归一化
 - 直连边
 - 逐位的FNN

LayerNorm: 句子长度不一致, 并且各个batch的信息没什么关系, 因此只考虑句子内信息的归一化



Multi-Head Attention Multi-Head Attention




Transformer

<https://mchromiak.github.io/articles/2017/Sep/12/Transformer-Attention-is-all-you-need/#.W90QB5Mzabg>



“Add & Norm” 表示残差连接和层归一化

$N \times$ 表示重复 N 次



Transformer

Transformer模型的结构



➤ encoder和decoder的self-attention层和FFN层都有残差连接。反向传播的时候减少梯度消失。




BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding


Jacob Devlin Ming-Wei Chang Kenton Lee Kristina Toutanova


Google AI Language

{jacobdevlin, mingweichang, kentonl, kristout}@google.com




BERT 用 **WordPiece** 工具来进行分词，并插入特殊的分隔符（**[CLS]**，用来分隔样本）和分隔符（**[SEP]**，用来分隔样本内的不同句子）。







(a) Sentence Pair Classification Tasks:
MNLI, QQP, QNLI, STS-B, MRPC,
RTE, SWAG



(b) Single Sentence Classification Tasks:
SST-2, CoLA



(c) Question Answering Tasks:
SQuAD v1.1



(d) Single Sentence Tagging Tasks:
CoNLL-2003 NER

BERT: Bidirectional Encoder Representation from Transformers

Self-Attention Applied

Language Processing



An armchair in the shape
of an avocado

Transformers: BERT, GPT

Devlin et al., *NAACL* 2019
Brown et al., *NeurIPS* 2020


Biological Sequences



AlphaFold2

Jumper et al., *Nature* 2021

Computer Vision



Vision Transformers

Dosovitskiy et al., *ICLR* 2020



1. 什么是注意力？注意力有两种类型？
2. 什么是软性注意力机制？解释软性注意力机制的计算步骤。
3. 注意力打分函数有哪些主要的模型？这些模型的优缺点是什么？在文本分类、机器翻译、图像文本描述等实际任务中如何应用注意力模型？
4. 什么是键值对注意力？
5. 为什么说基于卷积或循环网络的序列编码都是一种局部的编码方式？为什么说全连接神经网络无处理变长的序列问题？为什么说自注意力模型可以建立输入序列之间的长距离依赖关系？
6. 自注意力模型的优缺点是什么？
7. 自注意力模型中为什么要用三个独立的投影矩阵生成Q、K、V？
8. 多头自注意力有什么优势？
9. Transformer中除了自注意力，还有位置编码、层归一化、直连边、逐位的FNN，请解释层归一化、直连边、逐位的FNN的作用。