




浙江工业大学
ZHEJIANG UNIVERSITY OF TECHNOLOGY

厚德
取精
健行
用弘



大语言模型 与AI智能体



学习内容

CONTENTS

1

大模型概述

2

DeepSeek的部署和调优


3

大模型智能体

4

发展趋势

Vaswani, Ashish, et al. "Attention is all you need." *Advances in Neural Information Processing Systems*. 2017.




GPT-4（2023. 3.15发布），**GPT-5**（2025. 8 发布）


Deepseek R1（2025. 1 发布）

Gemini（2023. 12.6发布），**Gemini 2.5**（2025.3.26发布）

DeepSeek 全球增速最快AI应用



超级产品 增长1亿用户所用的时间






低成本

绕过CUDA挖掘FP8硬件潜力，MOE和MLA技术实现不到10%的成本方案

~150M\$ → **5.57M\$**
Llama3.1-405B训练成本 DeepSeek-V3训练成本



DeepSeek-R1推理成本仅为OpenAI o1的3%

低成本完美对标OpenAI O1，突破精确语义理解及复杂推理任务

DeepSeek-V3是一款MoE模型，总参数量671B，激活参数量37B，采用2048张H800（节点内NVLink，节点间IB，非超节点架构）在14.8T token数据集上基于自研 HAI-LLM 训练系统总计训练了1394h（58.08天）

模型	训练成本	调用成本 (输入/百万 tokens)	调用成本 (输出/百万 tokens)
DeepSeek-V3	557.6万美元	0.14美元 (缓存未命中) / 0.014美元 (缓存命中)	0.28美元
DeepSeek-R1	未明确 (推测低于V3)	0.14美元 (缓存命中) / 0.55美元 (缓存未命中)	2.19美元
OpenAI GPT-4o	10亿美元	2.5美元 (缓存未命中) / 1.25美元 (缓存命中)	10美元
OpenAI o1	未明确 (推测高于GPT-4o)	15美元 (缓存未命中) / 7.5美元 (缓存命中)	60美元
Claude 3.5 Sonnet	5亿美元	3美元	15美元



低成本完美对标OpenAI O1，突破精确语义理解及复杂推理任务

DeepSeek-V3是一款MoE模型，总参数量671B，激活参数量37B，采用2048张H800（节点内NVLink，节点间IB，非超节点架构）在14.8T token数据集上基于自研 HAI-LLM 训练系统总计训练了1394h（58.08天）

低成本

绕过CUDA挖掘FP8硬件潜力，MOE和MLA技术实现不到10%的成本方案


~150M\$ → **5.57M\$**
Llama3.1-405B训练成本 DeepSeek-V3训练成本



DeepSeek-R1推理成本仅为OpenAI o1的3%

性能优

数学、科学和代码等领域领先业界，成为业界公认的LLM的领先模型



来源：DeepSeek模型测试数据&互联网

技术创新

硬件级、算法级、架构级、工程级、开源生态5大技术创新，轰动全球

- 硬件级优化**
 - 绕过CUDA进行PTX编程
 - 计算与通信优化，性能提升30%
- 算法革命**
 - GRPO：群体进化的智慧筛选器
 - 自我验证机制：AI的“错题本系统”
- 架构创新**
 - 混合专家模型的“智能路由器”
 - 多头潜在注意力MLA：空间压缩术
- 工程奇迹**
 - 训练框架加速：16到3的量化压缩，通信降低89%
 - 推理加速：预加载，动态批处理等
- 开源生态**
 - 模型、数据、工具链、部署全开源
 - 蒸馏技术使能第三方模型性能

1 1.2 DeepSeek-V4 的主要优势



百万 token 上下文成开源标配，Agentic 能力比肩顶级闭源模型

DeepSeek-V4 (2026 年 4 月开源预览版) 是 MoE 大模型，含 **V4-Pro** (总参 1.6T / 激活 49B) 与 **V4-Flash** (总参 284B / 激活 13B)，两款均**原生支持 100 万 token 上下文**。融合 CSA+HCA 混合注意力与自研 DSA 稀疏注意力，引入 mHC 超连接与 Muon 优化器，长上下文效率全球领先。

极致效率

绕过算力瓶颈，上下文 ×8 而单 token 算力反降

128K → 1M

原生上下文长度 (百万 token)

长上下文计算量 ↓ 73%

1M 场景下单 token 算力仅 V3.2 的 27%、KV Cache 仅 10%

对比维度	DeepSeek-V4-Pro	DeepSeek-V4-Flash
参数量 (总 / 激活)	1.6T / 49B	284B / 13B
原生上下文长度	1M (百万 token)	1M (百万 token)
SWE-bench Verified	80.6%	接近 Pro
输入价格 (¥ / 百万 token)	1 命中 / 12 未命中	0.2 命中 / 1 未命中
输出价格 (¥ / 百万 token)	24	2


LiveCodeBench 93.5% 全球第一

Codeforces 3206 超 GPT-5.4

SWE-bench 80.6% 逼近 Opus 4.6 (80.8%)

世界知识开源第一 仅次于 Gemini-3.1-Pro

$L = 61$ 层




MoE: 1 共享专家+
256 路由专家

MLA: 低秩压缩


■ DeepSeek V3 模型参数?

■ 671B 参数 (GPT-3: 175B、GPT-4: 1.76T?)


■ 每个 token 激活 37B参数(~5.5%), 降低计算量



- 核心技术DeepSeekMoE: **显著减少计算量** (穷则战术穿插)
 - 针对美国的**算力禁令**
 - 核心思想: 1 共享专家 +256 路由专家, 激活 8 个路由专家
 - 共享专家: 捕获通用知识、降低知识冗余
 - 路由专家: 量大、细粒度、灵活组合、方便知识表达
 - 结果: 每个Token只要过360亿参数 (Llama 3.1要4050亿参数)



- **MLA: 少许计算量换HBM空间 (穷则战术穿插, 已开源)**
 - 针对美国的**HBM芯片禁令**(AI算力严重依赖高性能内存)
 - 核心思想: 低秩压缩 KV, 显著降低推理时 KV cache 的存储空间需求
 - 结果: KV Cache 使用降低 93.3%
 - 推理性能: 显著提升
 - 推理成本: 显著降低





DeepSeek V3主要创新

- **Infrastructures**
- **Multi-Token Prediction (MTP)**


Infrastructures

- 减少流水线气泡
- 高效节点间All-to-All通信
- FP8训练
- 低精度存储与通信


MTP: 一次预测多个topken




DeepSeekMoE



Multi-Head Latent Attention (MLA)




V3规模: 671B total parameters, 37B activated parameters, trained on 14.8T tokens



生成式AI: 使用生成式模型生成**各类数据**（语言、语音、图片、视频等）

- **Attention:** 数据依存关系建模
- **Transformer:** 数据生成的统一架构
- **Scaling Laws:** 数据学习、生成的扩展法则
- **RLHF:** 生成与人类价值对齐的数据
- **o1/R1:** 生成式求解问题——生成复杂问题的答案（推理）



Chinchilla法则（Hoffmann et al. 2022）：在计算预算固定时，模型参数量和训练数据量应该平衡缩放

Jared Kaplan, Sam McCandlish, et al: Scaling Laws for Neural Language Models. [CoRR abs/2001.08361](#) (2020)


Hoffmann, J., et al. (2022). Training Compute-Optimal Large Language Models. [arXiv:2203.15556](#).

- **大语言模型** (Large Language Models, LLMs)：是指使用大量文本数据训练的深度学习模型，可以**生成自然语言文本**或**理解语言文本的含义**。

在**大量的文本数据**上进行训练，可以执行广泛的任务，包括文本总结、翻译、情感分析等等。

LLMs的特点是**规模庞大**，包含数十亿以上的参数。

- 核心能力：
 - **上下文学习**：可以通过完成**输入文本的词序列**来生成测试实例的预期输出，而无需额外的训练；
 - **指令遵循**：通过对自然语言描述（即指令）格式化的多任务数据集的混合进行微调，LLMs 在微小的任务上表现良好，这些任务也以指令的形式所描述。**指令调优**使 LLMs 能够在不使用显式样本的情况下通过理解任务指令来执行新任务，这可以大大提高泛化能力；




- **上下文学习**：可以通过完成**输入文本的词序列**来生成测试实例的预期输出，而无需额外的训练；
- **指令遵循**：通过对自然语言描述（即指令）格式化的多任务数据集的混合进行微调，LLMs 在微小的任务上表现良好，这些任务也以指令的形式所描述。**指令调优**使 LLMs 能够在不使用显式样本的情况下通过理解任务指令来执行新任务，这可以大大提高泛化能力；
- **循序渐进的推理**：对于小语言模型，通常很难解决涉及多个推理步骤的复杂任务。大模型可以通过**思维链推理策略（Chain of Thought, CoT）**，利用涉及中间推理步骤的 **prompt 机制（提示工程）** 来解决此类任务得出最终答案。

数学题：一个商店里，上午卖出 5 件衣服，下午卖出的是上午的 2 倍，晚上卖出 10 件，全天一共卖出多少件？

模型不会直接给出答案，而是先拆解步骤：

第一步，计算下午卖出的数量： $5 \times 2 = 10$ 件；

第二步，将上午、下午、晚上的数量相加： $5 + 10 + 10 = 25$ 件”，最终得出结果。



Zhao et al. A Survey of Large Language Models. arXiv:2303.18223

训练LLMs需要向其提供大量的文本数据，模型利用这些数据来学习人类语言的结构、语法和语义。

LLMs采用**自监督学习** (self-supervised learning) 的技术，模型通过预测序列中的下一个词或标记，为输入的数据生成自己的标签，并给出之前的词，并迭代这个过程。

- 训练过程包括两个主要步骤：预训练（pre-training）和微调（fine-tuning）：
 - 在**预训练阶段**，模型从一个巨大的、多样化的数据集中学习，通常包含来自不同来源的数十亿词汇，如网站、书籍和文章。这个阶段允许模型学习一般的语言模式和表征。
 - 在**微调阶段**，模型在与**目标任务**或领域相关的更具体、更小的数据集上进一步训练。这有助于模型微调其理解，并适应任务的特殊要求。


GPT（生成式模型）的工作过程：单字接龙

模型输入：我们

模型输出：提出了一个新的和简单的模型

文本生成的过程本质就是单字接龙。

思考：单字接龙为什么可以产生这么大的威力？



ChatGPT构建流程

主要包含四个阶段：预训练、有监督微调、奖励建模、强化学习。这四个阶段都需要不同规模数据集以及不同类型的算法，会产出不同类型的模型，同时所需要的计算资源也有非常大的差别。

	预训练	有监督微调	奖励建模	强化学习
数据集	原始数据 数千亿单词：图书、百科、网页等	标注用户指令 数万用户指令和对应的答案	标注对比对 百万量级标注对比对	用户指令 十万量级用户指令
算法	语言模型训练	语言模型训练	二分类模型	强化学习方法
模型	基础模型	SFT 模型	RM 模型	RL 模型
资源需求	1000+GPU 月级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间

信息来源：OpenAI 联合创始人
Andrej Karpathy 在微软 Build
2023 大会上汇报，复旦大学张
奇等整理

ChatGPT构建流程

ChatGPT构建的四个阶段：预训练、有监督微调、奖励建模、强化学习。

自监督预训练

有监督训练
(指令微调)

强化学习
(无监督)

ChatGPT

	预训练	有监督微调	奖励建模	强化学习
数据集	原始数据 数千亿单词：图书、 百科、网页等	标注用户指令 数千万用户指令和对应 的答案	标注对比对 百万量级标注对比对	用户指令 十亿量级用户指令
算法	语言模型训练	语言模型训练	二分类模型	强化学习方法
模型	基础模型	SFT 模型	RM 模型	RL 模型
资源需求	1000+GPU 月级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间

奖励建模
(有监督训练)


阶段一 自监督预训练 (Unsupervised pre-training)

核心思路：利用前 k 个词 (token) 预测第 $k+1$ 个词。

设有语料 $U = \{u_1, \dots, u_n\}$, 则预训练目标为:

$$\text{Min} - \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \theta)$$


其中 $P(u_i)$ 表示模型输出词语 (token) 是 u_i 的概率, θ 表示网络中的可变参数。



阶段一 自监督预训练 (Unsupervised pre-training)

海量训练数据包括互联网网页、维基百科、书籍、GitHub、论文、问答网站等，构建包含数千亿甚至数万亿单词的具有多样性的内容。

基础大模型构建了长文本建模能力，隐含的构建了包括事实性知识和常识知识在内的世界知识，根据输入的提示词 (Prompt)，模型可以生成文本补全句子。



阶段二 有监督微调/指令微调（Supervised Fine-tuning/Instruction Tuning）

也称为指令微调（Instruction Tuning），在阶段一的模型上继续训练。


训练数据为高质量数据集，包含用户输入的提示词（Prompt）和对应的理想输出结果。用户输入包括问题、闲聊对话、任务指令等多种形式和任务。

	预训练	有监督微调	奖励建模	强化学习
数据集	原始数据 数千亿单词：图书、百科、网页等	标注用户指令 数千万用户指令和对应的答案	标注对比对 百万量级标注对比对	用户指令 十万量级用户指令
算法	语言模型训练	语言模型训练	二分类模型	强化学习方法
模型	基础模型	SFT 模型	RM 模型	RL 模型
资源需求	1000+GPU 月级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间	1-100GPU 天级别训练时间

阶段二 有监督微调/指令微调 (Supervised Fine-tuning/Instruction Tuning)


提示词 (Prompt)：浙江工业大学有几个校区？

理想输出：浙江工业大学有三个校区，分别是朝晖校区、屏峰校区、莫干山校区。其中朝晖校区位于杭州市拱墅区，屏峰校区位于杭州市西湖区，莫干山校区位于湖州市德清县。



阶段二 有监督微调/指令微调 (Supervised Fine-tuning/Instruction Tuning)

经过微调后的有监督微调 (SFT) 模型具备了初步的指令和上下文理解能力，能够完成开放领域问题、阅读理解、翻译、生成代码等能力，也具备了一定的对未知任务的泛化能力。




阶段三 奖励建模（Reward Modeling）

奖励建模（Reward Modeling）阶段的目标是构建一个文本质量评估模型。

奖励建模（Reward Modeling）用来对SFT模型的输出文本进行质量评估。

为训练得到奖励模型，须人工标注百万量级的样本库，奖励模型的训练过程独立于GPT模型。



阶段三 奖励建模（Reward Modeling）

奖励建模（Reward Modeling）阶段的目标是构建一个文本质量评估模型。


把同一个提示词多次传入SFT 模型，会得到多个不同输出结果，奖励模型可以对这些结果的质量进行排序。


B A team of researchers from Yale University and University of California, Davis studied the vocalization patterns of several different types of parrots. They found that parrots like to mimic human speech, and can produce a wide range of sounds, such as whistles, squawks, and other types of vocalizations...	C Parrots have been found to have the ability to understand numbers. Researchers have found that parrots can understand numbers up to six. In a series of experiments, the parrots were able to identify the amount of food items under a number of cups...			
A A research group in the United States has found that parrots can imitate human speech with ease, and some of them can even do so in the same way as humans. This group studied the sounds that parrots make in their natural habitats and found that they use their tongues and beaks in ways that are strikingly...		E Scientists have found that green-winged parrots can tell the difference between two noises that are the same except for the order in which they are heard. This is important because green-winged parrots are known to imitate sounds. This research shows that they are able to understand the difference between sounds.		
		D Current research suggests that parrots see and hear things in a different way than humans do. While humans see a rainbow of colors, parrots only see shades of red and green. Parrots can also see ultraviolet light, which is invisible to humans. Many birds have this ability to see ultraviolet light, an ability		

阶段四 强化学习（Reinforcement Learning）

强化学习（Reinforcement Learning）阶段是对指令微调（SFT）模型的进一步训练。

根据数十万用户给出的提示词，SFT模型生成相应输出，然后再利用奖励模型（RM）对这些输出进行质量评估。结合评估结果再对SFT模型进一步调整，最终得到ChatGPT。





- OpenAI的GPT-4o、DeepSeek V3、豆包等通用模型都属于**指令模型 (Insturct Model)**，是专门设计用于**遵循指令**生成内容或执行任务的；需要通过提示词的各类技巧才能激发模型更好的表现。
- DeepSeek R1 属于**推理模型 (reasoning model)**，专注于逻辑推理、问题解决的模型，能够自主处理需要多步骤分析、因果推断或复杂决策的任务；只需要清晰、明确地表达具体的需求即可。OpenAI的o1也是推理模型。

- 一般来说, “**推理**” 定义为回答那些需要复杂的、多步骤生成的、包括中间步骤的问题的过程。
- 大多数现代LLM能够进行基本推理, **推理模型**的LLM都包括 “**思考**” 或 “**思维**” 过程, 作为其回答的一部分。

If a train is moving at 60 mph and travels for 3 hours, how far does it go?

The train travels 180 miles.

Plain response

To determine the distance traveled,
use the formula:

Distance = Speed $\times$ Time

Given that the speed is 60 mph and
the time is 3 hours:

Distance = 60 mph $\times$ 3 hours = 180 miles


So, the train travels 180 miles.

Response with intermediate
reasoning steps

- 一般来说，“**推理**”定义为回答那些需要复杂的、多步骤生成的、包括中间步骤的问题的过程。
- 大多数现代LLM能够进行基本推理，**推理模型**的LLM都包括“**思考**”或“**思维**”过程，作为其回答的一部分。

维度	推理模型	通用模型
优势领域	数学推导、逻辑分析、代码生成、复杂问题拆解	文本生成、创意写作、多轮对话、开放性问答
劣势领域	发散性任务（如诗歌创作）	需要严格逻辑链的任务（如数学证明）
性能本质	专精于逻辑密度高的任务	擅长多样性高的任务
强弱判断	并非全面更强，仅在其训练目标领域显著优于通用模型	通用场景更灵活，但专项任务需依赖提示语补偿能力

- 目前，大模型依然具有一定的**局限性**，主要表现在以下几个方面：
 - 训练时将内容**token**化：预训练本质上是让模型建立文本片段之间的关联规律。为了实现这个目标，所有训练数据（包括书籍、网页、对话记录等）都会经过特殊处理，将文本切割成称为token的基本单元（类似文字的“碎片”），然后将这些token转化为数字编码。



单词 "strawberry" 中有 3个字母“r”。

你可以逐个字母检查：

s-t-r-a-w-b-e-r-r-y

其中，第3、第8和第9个字母是“r”。

这是一个有趣的问题，因为许多AI模型在处理这种看似简单的问题时容易出错，主要是由于分词机制和推理模式的局限性。但通过逐步分析，答案非常明确：**3个“r”**。



strawberry有几个r

- 模型知识是存在**截止时间**的：
 - 预训练阶段需要处理PB级原始数据；数据清洗需要经历去重、脱敏、质量验证等工序；后期还要进行监督微调、基于人类反馈的强化学习（RLHF）等迭代优化。
 - 优化方案：（1）**激活联网搜索功能**：给R1提供自主搜索查找信息的权力；（2）**补充必要知识**：通过上传文档、在提示词中提供充足的信息之后，再让R1去执行具有更近时效性的任务。

你的知识库更新到什么时候

我的知识库更新到答。

复制 再试-



我的知识库更新截止到 **2024年7月**。这意味着我可以提供截至该时间点的信息、数据和知识。如果你有关于最新事件或动态的问题，我会尽力基于已有知识提供帮助，但可能无法覆盖2024年7月之后的内容。如果你需要更实时的信息，建议结合其他工具或资源进行查询！ 😊




1

1.4 大模型的局限性

• 记忆有限

- 多数大模型都有上下文长度的限制，因此输入输出都有长度限制。如果发送的文档长度超过限制，可以通过 **RAG (Retrieval - Augmented Generation)**检索增强生成方式。

假设您有一个100页的PDF文档，想询问“第50页提到的技术规格是什么？”



我的上下文 token 长度限制为 **128,000 tokens**。这意味着在一次对话中，我可以处理和理解最多 128,000 个 token 的文本内容（包括用户输入和我的回复）。这让我能够支持较长的对话、复杂的任务以及大段文本的分析和处理。

如果你有需要处理的长文本或复杂任务，可以随时告诉我！ 😊



基于以下上下文回答用户问题：

上下文1：[检索到的片段1]

上下文2：[检索到的片段2]

用户问题：[原始查询]

- 大模型**幻觉 (Hallucination)** 问题:
 - 压缩训练数据时，模型难免会产生一定的幻觉（**模型生成了看似合理但却与事实相违背的内容**）；
 - 生成模型存储的是输入（文本或图像像素点）之间关系（概率）的数学表征；
 - 模型倾向于不完美地“填补空白”或产生幻觉，模型会在缺少信息的情况下进行猜测，从而产生不准确的输出。
- 幻觉类型：
 - 逻辑谬误**：模型在进行推理时出现了错误，提供错误的答案；
 - 捏造事实**：模型自信地断言不存在的事实，而不是回答“我不知道”；
 - 数据驱动的偏见**：由于某些数据的普遍存在，模型的输出可能会偏向某些方向，导致错误的结果。



- **DeepSeek-V3**
 - **通用型模型**：专注于自然语言处理、知识问答、内容创作等通用任务，目标是实现高性能与低成本的平衡，适用于智能客服、个性化推荐系统等场景。
- **DeepSeek-R1**
 - **推理专用模型**：专为数学、代码生成和复杂逻辑推理任务设计，通过大规模强化学习（RL）提升推理能力，对标OpenAI o1系列。

场景	DeepSeek-V3	DeepSeek-R1
适用领域	自然语言处理、知识问答、创意文案生成	数学建模、代码生成、复杂逻辑推理任务
开发者工具	支持本地部署，适合中小规模应用	提供蒸馏小模型（1.5B-70B），适配资源有限场景
API特性	高性价比，适合通用需求	支持“DeepThink+”模式输出思维链，适合专业开

模型尺寸	参数量	特点	适用场景	硬件配置
1.5B	15亿	轻量级，快速响应	轻量级任务（如短文本生成、基础问答）	4核处理器、8GB内存，无需显卡（个人量级）
7B/8B	70-80亿	平衡型，性能适中	中等复杂度任务（如文案撰写、代码生成）	8核处理器、16GB内存，RTX 3060/4060（个人量级）
14B	140亿	高性能，适合复杂任务	数学推理、代码生成、长文本处理	i9-13900K、32GB内存，RTX 4090/A5000（公司入门级）
32B	320亿	专业级，高精度任务	医疗/法律咨询、大规模训练、金融预测	Xeon 8核、128GB内存，2-4张A100（公司级）
70B	700亿	顶级模型，大规模计算高	精度专业领域任务、多模态任务预处理	8张A100/H100，128GB内存（公司级）
671B	6710亿	满血版，接近人类专家级推理能力	前沿科学研究、复杂商业决策分析	16-32张A100/H100，极高硬件需求（硬件成本约200-300万）



- 网页版/APP使用的**局限性**:
 - 数据隐私：联网使用大模型数据隐私无法得到保证；
 - 上传文件的限制：对于上传文件有数量和大小的限制
 - 仅通过附件扩展上下文功能有限：每次新的对话中提问相关问题，需要重新上传附件；修改删除对话中已经上传的附件操作困难。
- 本地部署的优势：
 - **隐私保护**：通过本地部署解决隐私问题
 - **个性化知识库构建**：通过RAG (Retrieval-Augmented-Generation) 构建
 - RAGFlow 或 AnythingLLM
 - Embedding 大模型（或者自带Embedding模型的RAGFlow版本）




- 本地部署流程
 - 下载**ollama**，通过ollama将DeepSeek模型下载到本地运行 **环境部署**
 - 下载**RAGFlow**和**Dockers**，通过Docker部署RAGFlow **环境部署**
 - 在RAGFlow中构建**外部知识库**，并实现基于外部知识库的对话问答。 **构建知识库**
 - 采用AnythingLLM的APIKey进行基于web端的二次开发 **生成APIKey**
- 外部知识库+在线大模型
 - 下载**RAGFlow**和**Dockers**，通过Docker部署RAGFlow
 - 通过APIKey调用企业大模型
 - 缺点：隐私安全和调用API的成本

- 策略一：提示工程（Prompting）——用语言引导模型输出
- 策略二：微调优化——让模型适配特定领域
- 策略三：知识库增强（RAG）——让模型 “有书可查”
- 提示工程（Prompting）不需要改变模型结构和进行额外大模型训练
 - Chain-of-Thought (CoT) 是一种在自然语言处理（NLP）领域中用于推理的策略。CoT 的核心理念是通过**分解问题**，模拟人类思考的逐步推理过程，从而帮助模型更好地理解**复杂任务**，并给出更准确的答案。
 - CoT（思维链）方法的关键思想是让模型生成一个有序的推理链条，而不是直接跳到结论。
 - CoT 方法将复杂的任务分解成一系列子任务或中间步骤，每个步骤都提供更加详细的推理信息，帮助模型通过推理得出最终的正确结论。
 - 通过逐步推理，CoT 的思维方式不仅提高了解决复杂问题的准确性，也增强了模型的可解释性。

提示语 (Prompt) 是用户输入给AI 系统的指令或信息，用于引导AI生成特定的输出或执行特定的任务。简单来说，提示语 就是我们与AI “对话” 时所使用的语言，它可以是一个简单的问题，一段详细的指令，也可以是一个复杂的任务描述。

提示语的基本结构包括指令、上下文和期望

- 指令(Instruction): 这是提示语的核心，明确告诉AI你希望 它执行什么任务。
- 上下文(Context): 为AI提供背景信息，帮助它更准确地理解和执行任务。
- 期望(Expectation): 明确或隐含地表达你对AI输出的要求和预期。



提示语 (Prompt) 是用户输入给AI系统的指令或信息，用于引导AI生成特定的输出或执行特定的任务。简单来说，提示语就是我们与AI“对话”时所使用的语言，它可以是一个简单的问题，一段详细的指令，也可以是一个复杂的任务描述。

提示语的基本结构包括指令、上下文和期望

- 指令(Instruction): 这是提示语的核心，明确告诉AI你希望它执行什么任务。
- 上下文(Context): 为AI提供背景信息，帮助它更准确地理解和执行任务。
- 期望(Expectation): 明确或隐含地表达你对AI输出的要求和预期。

你现在是一名公司数据分析员工，需要给领导一份 2024 年第四季度点数据分析报告，要求语言精练，数据详实，你可以给我提供一份报告模板吗，报告内容一定要说人话



已深度思考 (用时 29 秒) ▾

嗯，用户需要一份 2024 年第四季度的数据分析报告模板，作为公司数据分析员工给领导看的。首先，得明确用户的需求，他们希望语言精练、数据详实，而且要说人话，也就是避免使用过于专业的术语，让领导容易理解。

首先，我要考虑报告的结构。通常数据分析报告包括概述、核心数据、关键发现、挑战与建议、未来展望这几个部分。但是用户强调要精练，所以每个部分不能太长，要突出重点。

接下来，核心数据部分需要涵盖营收、成本、利润、市场占有率这些关键指标。可能需要用对比分析，比如环比和同比，来展示增长或下降的情况。用户提到要数据详实，所以可能需要具体的例子，比如营收增长了多少百分比，利润情况如何。

1.明确问题背景

梳理问题的基础信息，比如问题是在什么场景下产生的、涉及哪些对象等

示例:

低效提问: “怎么提升客单价?”

高效提问: “我是蜜雪冰城的产品运营, 希望通过12个月的周期提升客单价, 同时稳住市场份额, 能接受短期业绩波动, 有什么具体方案?”

高效向 DeepSeek 提问模版



1. 我的角色/背景: [例如: 我是蜜雪冰城的产品运营]
2. 我的问题场景: [例如: 希望通过12个月的周期提升客单价]
3. 我的目标: [例如: 提升客单价至15元, 同时稳住市场份额]
4. 我的限制条件: [例如: 能接受短期业绩波动]
5. 期望的回答形式: [例如: 需要具体的执行方案, 包括产品升级、套餐设计等]

2.提供具体信息

包括: 您的角色 (如产品经理、学生、创业者等)。问题的具体场景 (如 “针对老年人团队的重庆旅游攻略”)。

您的目标 (如 “提升客单价” “设计一个 2 天行程”)。
限制条件 (如 “预算有限” “不接受过度劳累”)。

示例:

低效提问: “重庆怎么玩?”

高效提问: “我计划2月初带老年人团队去重庆玩2天, 希望行程轻松、避开人流高峰, 有什么推荐路线和注意事项?”

1.明确问题背景

梳理问题的基础信息，比如问题是在什么场景下产生的、涉及哪些对象等

2.提供具体信息

包括：您的角色（如产品经理、学生、创业者等）。
问题的具体场景（如“针对老年人团队的重庆旅游攻略”）。

您的目标（如“提升客单价”“设计一个 2 天行程”）。
限制条件（如“预算有限”“不接受过度劳累”）。

3.结构化描述问题

复杂问题拆解为多个小问题，或列出关键点。

示例：

低效提问：“怎么提升客单价？”

高效提问：“我是蜜雪冰城的产品运营，希望通过12个月的周期提升客单价，同时稳住市场份额，能接受短期业绩波动，有什么具体方案？”

示例：

低效提问：“重庆怎么玩？”

高效提问：“我计划2月初带老年人团队去重庆玩2天，希望行程轻松、避开人流高峰，有什么推荐路线和注意事项？”

示例：

低效提问：“怎么运营一个品牌？”

高效提问：“我想运营一个新茶饮品牌，目前有以下问题：
如何定位目标用户？
如何设计产品线？
如何通过社交媒体吸引第一批用户？”

- **微调**：在现有的预训练的模型基础上，结合特定任务的数据集进一步进行训练，使得模型在这一领域表现得更好
 - 采用OpenMind Library + Transformers + **专业数据集**
 - **Reasoning数据集**是一类专门用于训练和评估模型推理能力的数据集。它们通常涉及复杂的逻辑推理、常识推理、数学推理、因果推理等任务，能够帮助模型处理多步骤推理问题和复杂推理情境。



- **EmoLLM数据集** 心理医生的口吻回答问题
 - 数据集按用处分为两种类型：General 和 Role-play
 - 数据按格式分为两种类型：QA 和 Conversation
 - 数据汇总：General (9个数据集)；Role-play (5个数据集)

数据集类型

- General：通用数据集，包含心理学知识、心理咨询技术等通用内容
- Role-play：角色扮演数据集，包含特定角色对话风格数据等内容


数据类型

- QA：问答对
- Conversation：多轮对话

数据集汇总

Category	Dataset	Type	Total
General	data	Conversation	5600+
General	data_pro	Conversation	36,500+
General	multi_turn_dataset_1	Conversation	36,000+
General	multi_turn_dataset_2	Conversation	27,000+
General	multi_turn_dataset_3	Conversation	1,517,300+
General	single_turn_dataset_1	QA	14,000+
General	single_turn_dataset_2	QA	18,300+
General	self_cognition_EmoLLM	QA	85+
General	ruozhiba_raw	QA	240+
Role-play	aiwei	Conversation	4000+
Role-play	SoulStar	QA	11,200+
Role-play	tiangou	Conversation	3900+
Role-play	mother	Conversation	40,300+
Role-play	scientist	Conversation	28,400+

- DeepSeek 作为强大的大模型，提供了优质的基础能力
- 在特定任务（如医学、法律、金融等应用领域），直接使用可能会导致：
 - 模型泛化能力不足：无法精准理解专业术语或行业特定语言风格。
 - 推理性能欠佳：无法高效完成某些需要深度推理的任务。
 - 资源浪费：直接使用完整大模型进行训练需要极高计算资源。
- 采用高效微调策略，如 **LoRA (Low-Rank Adaptation)**、**全参微调**，可以在减少计算资源消耗的同时，实现高效定制化优化。
- LoRA**
 - 适用于 计算资源有限 的场景。
 - 只对部分权重进行低秩矩阵更新，减少显存占用。
 - 训练速度快，适合小样本微调。
- 全参微调 (Full Fine-tuning)**
 - 适用于 计算资源充足，任务复杂 的场景。
 - 对模型所有参数进行更新，适用于大规模数据训练。
 - 训练成本高，但微调效果最佳。





LoRA

$$W = W_0 + \underbrace{A}_{\text{frozen}} \underbrace{B}_{\text{trainable}}$$

Diagram illustrating the LoRA (Low-Rank Adaptation) structure. It shows a large matrix W (orange grid) being decomposed into a low-rank matrix A (green grid) and a matrix B (green grid). The low-rank matrix A has dimensions $n \times r$ and the matrix B has dimensions $r \times n$. The product $A \times B$ is shown as a small green grid. The text "low rank $r \ll n$ " is written above the product. The matrix W_0 is labeled "frozen" and the matrices A and B are labeled "trainable".

- **RAG技术** (Retrieval-Augmented-Generation)
 - 检索：当用户提出问题时，系统会从外部的知识库中检索出与用户输入相关的内容
 - 增强：系统将检索到的信息与用户的输入结合，扩展模型的上下文，然后再传给生成模型 (DeepSeek)
 - 生成：生成模型 (DeepSeek) 基于增强后的输入生成最终的回答。
 - 由于参考了外部知识库中的内容，回答更具有专业性和准确可读。
- **检索**的过程：
 - 准备外部知识库：可以采用本地文件、搜索引擎的结果、API等等
 - 通过**Embedding (嵌入)**模型，对知识库文件进行解析：Embedding的主要作用是将自然语言转化为机器可以理解的高位向量，并且通过这一过程捕获到文本背后的语义信息（比如不同文本之间的相似度关系）
 - 将用户的提问匹配外部知识库：将用户的提问生成高维向量，去查询知识库中相关的文档片段，采用余弦相似度等相似度度量算法去判断相似度
- 模型分类：Chat模型，Embedding模型





- **大模型智能体** (LLM-based Agent) 是一个能够**感知环境**、**自主决策**、**调用工具**并采取行动以**实现既定目标**的**计算系统**。
- 在大模型时代, Agent 的核心特征是把 LLM 作为大脑 (cognitive core), 再通过外挂的记忆、工具与机制, 使其突破“纯文本生成”边界, 成为可交互、可执行、可持续演化的闭环系统。
 - 1) AI Agent 以大模型技术为驱动, 大模型以AI Agent 为业务触手。
 - 2) 不同的大模型应用行业应用, 往往会催生不同的AI Agent。
 - 3) 两者相辅相成、相得益彰, 共同拓展着AI的应用边界和通用能力。

Profile: 智能体的“人设”，定义了其角色属性、行为风格、专业领域。

Memory: 智能体的“记忆系统”，分为短期记忆和长期记忆。

Planning: 智能体的“规划能力”，负责将复杂任务分解为可执行的步骤。

Action: 智能体的“执行能力”，通过调用工具（API、数据库、硬件设备）将计划落地。




Fig. 2 A unified framework for the architecture design of LLM-based autonomous agent.

在扣子空间：)

和 Agent 一起开始你的工作 🤖 |

扣子空间是你和 AI Agent 协同办公的场所。

在扣子空间里，精通各项技能的「通用实习生」，各行各业的「领域专家」，任你选择。

打开网页版

🍏 iOS

🐼 Android



生产力全面提升

从回答问题，到解决问题，让 Agent 帮你完成更多的工作

专家能力深度支持

专家Agent生态，让更专业 Agent 来为你提供服务

协作模式灵活调整

采用规划/探索双模式，更好地与 Agent 一起协作完成任务

能力边界拓展延伸

集成 MCP 扩展，无限拓展 Agent 能力边界

研究报告

市场调研报告分析

分析一下国家电投近几年整体的发展情况和投资情况，包括重点行业布局、出资...



社媒调研

社媒用户热门讨论

近期比较热门的Labubu配件（如娃娃、保护壳）有哪些？



播客创作

真人播客一键生成

电影《狂野时代》在戛纳电影节迎来全球首映，做个图文并茂的网页展示一下...



PPT 撰写

汇报总结一键生成

我是一个大学生，选修了电影赏析的通识课，现在要做一个期末PPT用于分享...



组件 模板 结构 数据

推荐组件

Text 图片 纵向列表 横向列表

按钮 表单 多行输入 AI 对话

布局组件

容器 纵向列表 横向列表 表格列表

瀑布流

展示组件

Text 图片 Markdo... 音频

图标 轮播 Lottie动画

输入组件

按钮 表单 单行输入 多行输入

数字输入 下拉选择 单选按钮 图片上传

售后客服-抖音电商同款(副本)

业务逻辑 用户界面

发布

用户界面

预览

订单详情 393 * 852

9:41 模拟电商页面

户外用品旗舰店 交易成功

户外防水徒步游泳... ¥159 黑色:35L 7天无理由退货 极速退款 ... x1

订单编号: 123456789 下单时间: 2023-10-05 14:30 订单状态: 已支付 发货状态: 待发货

返回首页

猜你喜欢

碳纤维登山杖手杖 ¥99 2000+人付款

夏季防晒帽 ¥159 2000+人付款

客服页面 393 * 852

9:41 户外用品旗舰店

人工客服: 小咪

哈喽小主! 我是你的专属客服, 请问你有什么问题呢? // 该模板可模拟实现客服领域-物流、支付、售后方向的相关问题 //

商品的发货时间是什么时候?

信用卡支付失败或被拒绝怎么办?

售后申请被驳回, 如何重新提交?


发送消息

内容由AI生成, 无法保证真实准确, 仅供参考。

智能体的开发流程:

- 创建 Bot 并设置人设
- 添加知识库
- 设计 workflows
- 发布并测试

3.2 大模型智能体开发实战





- AI思维：理解不同框架算法的能力边界和最佳应用场景
- 整合力：将AI能力与人的洞察能力有机结合，转化**领域专业知识**，整合新旧知识，重构工作方法；
- 引导力：结合应用场景设计**高效合理的指令词**，优化问题结构和把控输出质量，能够准确引导AI完成任务；
- 判断力：人工评估AI输出内容的可靠性、准确性和应用价值；构建后期微调的数据集。
- **人机共生**
 - 设计层次化提示词体系和结构
 - 设计人机协作流程，建立反馈优化循环
 - AI与专业知识融合，构建人机共生的新生态系统
 - 打造领域专属工具组合，建立人机共生特色

输入质量: 70% 人的影响

- 提示词的准确性和完整性
- 需求描述的清晰度

基础能力: 80% 机器的影响

- AI模型的能力边界
- 训练数据的质量

迭代优化: 90% 人的影响

- 反馈的精准度
- 优化的方向把控

人的关键影响路径

1. 提示工程 (决定性)
 - 清晰的目标定义
 - 准确的约束条件
 - 结构化的需求描述
2. 质量控制
 - 结果评估
 - 方向调整
 - 标准制定
3. 创意引导
 - 创意输入
 - 风格定义


机器的关键影响路径

1. 基础生成能力
 - 模型性能
 - 训练质量
 - 算法优化
2. 理解准确度
 - 语义理解
 - 上下文把握
3. 一致性保证
 - 输出稳定性
 - 质量基线

结论：对生成质量的影响，人的主导作用更大（约占65%）

原因：提示工程的质量和迭代优化的精准度是决定最终输出质量的关键

- **DeepSeek VL2**: 大型混合专家 (MoE) 视觉语言模型, 主要用于视觉问答、光学字符识别、文档/表格/图表理解和视觉定位。



- **DeepSeek VL2 Tiny** 10亿参数
- **DeepSeek VL2 Small** 28亿参数 (80G显存)
- **DeepSeek VL2** 45亿参数 (120G显存)

- ✓ 2025-2-6: Naive Implemented Gradio Demo on Huggingface Space [deepseek-vl2-small](#).
- ✓ 2024-12-25: Gradio Demo Example, Incremental Prefilling and VLMEvalKit Support.
- ✓ 2024-12-13: DeepSeek-VL2 family released, including `DeepSeek-VL2-tiny`, `DeepSeek-VL2-small`, `DeepSeek-VL2`.



om-ai-lab / VLM-R1 Public

[Code](#) [Issues 14](#) [Pull requests](#) [Actions](#) [Projects](#) [Security](#) [Insights](#)

main ▾

4 Branches 0 Tags

Go to file

<> Code ▾



snakeztc Create LICENSE


0d373cd · 12 hours ago

74 Commits

assets	fix qwen2.5vl flashattn bug	5 days ago
src	quick fix	12 hours ago
.gitignore	update code and readme	last week
Dockerfile	update baseline test	2 days ago
LICENSE	Create LICENSE	12 hours ago
README.md	shortern script example	16 hours ago
setup.sh	update code and readme	last week

这个项目的团队在 Qwen2.5-VL 的基础上，同时对比了 R1 和传统的 SFT^Q 方法。结果相当惊艳：

- 1、稳定性拉满：R1 方法在各种复杂场景下都能保持稳定的高性能，这在实际应用至关重要！
- 2、泛化能力^Q卓越：更让人震惊的是，在领域外的测试数据上，随着训练步数增加，传统 SFT 模型的性能开始下滑，而 R1 模型却能持续提升！这意味着 R1 方法帮助模型真正“学会”了理解视觉内容，而不是简单地记忆！



图片里展示了一桌子丰盛的美食，包括各种蔬菜、面饼和点心。针对图片，我们向模型提出了一个问题：“在图片中找出蛋白质含量最高的食物”。

模型不仅回答得准确：

“图片中展示了桌上的各种菜品，包括蔬菜、面饼和点心。从蛋白质含量来看，面饼或面点可能含量最高，因为它们通常由全谷物制成，面粉中含有蛋白质。虽然蔬菜也含有蛋白质，但比起这些主食来说含量较少。”



QwenLM / Qwen-Image Public

<> Code Issues 36 Pull requests 1 Actions Projects Security Insights

main

1 Branch 0 Tags

Go to file

<> Code



LooperXX Merge pull request #37 from Abraham3983/patch-1

4e3ce20 · yesterday

46 Commits

assets

Update Sample Code, Readme, and License.

4 days ago

src/examples

Update prompt_utils.py

3 days ago

LICENSE

Update Sample Code, Readme, and License.

4 days ago

README.md

Update README.md

yesterday

README

Apache-2.0 license



Qwen-Image

♥ [Qwen Chat](#)

| 🤖 [Hugging Face](#)

| 🤖 [ModelScope](#)

| 📄 [Tech Report](#)

| 📄 [Blog](#)

| 💻 [Demo](#)

| 💬 [WeChat \(微信\)](#)

| 🗨️ [Discord](#)

